第50卷 第17期 2026年9月10日
DOI：10.7500/AEPS20260121006
电力系统自动化
Automation of Electric Power Systems
Vol. 50 No. 17 Sept. 10，2026

面向算电协同的智算中心负荷灵活性：挑战与展望

王 奕，郭庆来
（清华大学电机工程与应用电子技术系，北京市 100084）

摘要： 人工智能（AI）的盛行引发智算中心能耗和碳排激增，源荷双侧的强波动性使得发掘内生负荷灵活性成为算电协同的关键。首先，针对AI计算任务与硬件设施的特殊性，剖析了智算中心负荷灵活性研究面临的多维度异构、细粒度耦合和多主体协同三大挑战。然后，从负荷建模、灵活性发掘与灵活性利用3个核心子问题出发，综述了国内外研究现状。最后，展望了未来研究的趋势，指出应重点推进适应多维度异构的任务级负荷建模，攻克感知细粒度耦合的灵活性动态刻画技术，设计激励多主体协同的灵活性拓展应用策略。

关键词： 算电协同；人工智能；智算中心；负荷灵活性；新能源；任务调度

0 引言

人工智能（artificial intelligence，AI）的盛行使得智算中心能耗大幅增长，为碳中和目标实现带来新增压力[1-2]。AI领域的规模法则揭示了模型性能与计算量的幂律关系[3]，推动了AI计算量与能耗的指数级增长[4]。据国际能源署报告，全球数据中心用电量预计在2030年将达到945 TW·h，约为日本目前的年总用电量[5]，其中，新增用电量约50%来源于面向AI应用的加速服务器[6]。

采用新能源作为智算中心的能量供应，能有效应对新增的减碳压力，但面临源荷两侧强波动性的问题。一方面，风能和太阳能具备建设周期短、成本低且可获取性广的优势，是实现算力碳中和的关键能源；特别地，中国新能源占新增装机总容量的比例达82.6%[7]且有序推动绿电直供模式[8]，新能源供能智算中心具备基建与政策的双重支持。另一方面，新能源依赖高维动态复杂大气系统，支撑在线AI推理服务的智算中心部分负荷源于海量人类行为聚合，两者均具随机性，且表现出日内周期性波动[9-10]，新能源的实际消纳效果受限。

发掘智算中心用电负荷的调节灵活性，对于提升新能源消纳效果至关重要。智算中心负荷灵活性的来源包括3种：通过计算量的时空分配改变时空负荷曲线[11-12]、通过制冷系统的热惯性改变制冷负荷的时序曲线、通过备用电源（以下简称备电，如燃料电池、储能）改变智算中心对外净负荷[13]等。所发掘的负荷灵活性不仅能够减轻新能源消纳压力、助力碳中和实现，还可以削减智算中心的用能成本。

现有负荷灵活性研究主要关注通算数据中心，对通算与智算之间的差异分析，以及对智算中心的系统探索尚不完善。面向通算数据中心负荷灵活性的研究相当丰富，在能耗建模[14]、能量管理[15-16]、需求响应[17]等问题上都取得了显著的学术成果。然而，智算中心与通算数据中心在计算任务、基础设施、业务运营3个层面均存在差异，为灵活性研究带来新的挑战，无法直接沿用面向通算的成果。

因此，本文围绕智算中心负荷灵活性，即智算中心功耗调节的能力，展开深入分析与调研。首先，将灵活性相关研究拆分为负荷建模、灵活性发掘、灵活性利用3个子问题：负荷建模构建调节手段与功耗之间的关系，提供模型基础；灵活性发掘提取可行调节手段并量化总调节能力，刻画负荷的可信边界；灵活性利用提供面向应用场景的解决方案，发挥灵活性价值。针对每一子问题，首先，通过智算中心相较于通算数据中心差异化特性的分析，揭示在子问题中面临的研究挑战；然后，综述国内外研究现状；最后，展望未来趋势，期望揭示智算中心负荷灵活性的研究热点和发展方向。

1 研究挑战

本章首先归纳了智算中心相较于通算数据中心的差异化特征，如表1所示。基于此，分析了智算中心负荷灵活性研究在负荷建模、灵活性发掘、灵活性利用3个子问题中的挑战，主要分别体现在以下3个方面：多维度异构、细粒度耦合、多主体协同。

收稿日期：2026-01-21；修回日期：2026-06-08。
上网日期：2026-07-13。
智能电网国家科技重大专项资助项目（2025ZD0804800）。

中国知网 https://www.cnki.net

表1　通算数据中心与智算中心的对比
Table 1　Comparison between general computing data center and intelligent computing center

主要特性	子特性	通算数据中心	智算中心
计算任务	任务的计算流程	由业务需求决定，表现为多个服务的调用	由模型结构、类别（训练和推理）、阶段（大模型推理中的预填充和解码）共同决定
	任务的设备需求	以中央处理器为主	中央处理器与专用算力芯片协同，后者包括图形处理器、张量处理器等架构
	任务到计算设备的映射	设备数可变，任务切分较简单：以实例数的横向增减为主	设备数可变，但任务切分复杂多变，涉及数据/张量/流水线/专家并行等混合并行策略
	任务的负荷曲线	较为平稳：有真实集群表现出20%的波动幅度[18]	波动较大：单个训练任务可表现出秒级75%波动幅度[19]，推理任务请求量日内60%波动幅度[10]
基础设施	功率密度	中低，单机架平均7.1 kW[20]	高，单机架约120 kW（NVIDIA DGX GB200 NVL72[21]）
	制冷技术	以风冷为主	以液冷为主，有调查显示采用液冷的智算中心占比预计在2026年9月将达79.6%[22]
	备电方式	集中式不间断电源＋柴油发电机	以集中式不间断电源＋发电机为主，采用机架级电池备份单元为补充成为趋势：有报告显示分布式供电容量年均增长率15%[23]
业务运营	收益来源	算力租用、平台服务	模型服务、算力租用
	定价方案	按租用时长计费，按服务功能计费	按模型产出计费（如词元量），按租用时长计费，按服务功能计费
	能效要求	新建大型数据中心的电能利用效率不高于1.25[24]	电能利用效率不高于1.25，准入值与先进值不高于1.22和1.18[25]

1.1　负荷建模：多维度异构

作为AI代表性技术，深度学习通过多个处理层组成的计算模型学习数据的多层次抽象表示[26]，其执行过程以多维度异构为重要特征，如图1所示可具体划分为3个维度。1）模型异构，即静态的计算图。典型的深度学习模型包括长短期记忆网络、卷积神经网络、图神经网络、Transformer等，各模型通过引入差异化的算子类型刻画数据的先验特征，分别适用于时序、局部性、图结构、全局交互的表征。作为提供AI开源工具的平台，Huggingface模型库所收集的模型总数已超过200万个[27]。2）硬件异构，即承载计算的物理对象。除去中央处理器外，AI适用芯片类型包括图形处理器（graphics processing unit，GPU）、张量处理器、神经网络处理器（neural processing unit，NPU）等，且每类加速器内部也存在代际差异（如流处理器数量、内存带宽等具体参数的更新）。3）运行时异构，即基于特定模型的计算任务在特定硬件上的映射方式。深度学习计算任务分为训练和推理两大类，特别地，大语言模型（large language model，LLM）推理，在键值缓存的优化技术中可进一步细分为预填充和解码阶段[28]：预填充阶段对所有输入信息进行编码，并将中间计算结果保存到内存中，是计算密集型任务；解码阶段则根据当前的编码信息生成下一个词元（token，即文本、图像等信息的最小表征单元），由于前序信息的中间计算结果无须重复计算但需要从内存中读取，是通信密集型任务。除去计算任务带来的算法流程上的差异，执行引擎针对特定任务的运行优化同样会产生硬件行为方面的差异，如并行策略、算子融合[29]、显存管理等[30]。

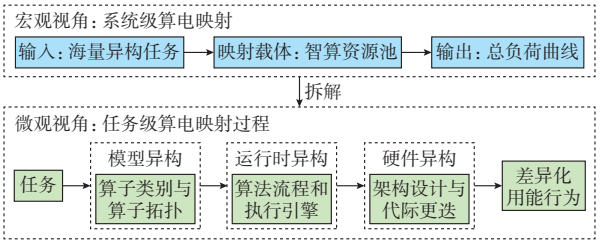


图1　AI计算任务执行过程的多维度异构
Fig. 1　Multi-dimensional heterogeneity involved in AI computing task execution process

这些软硬件多维度异构意味着，任务之间甚至是同一任务内，均会表现出差异化的用能行为和计算性能，以及相同调节手段下对功耗和性能的差异化影响，导致宏观视角下以任务量定功耗的算力负荷建模方法难以直接适用。此外，受需求驱动产生的海量异构任务，将造成智算中心级调度决策空间的大幅扩张。因此，灵活性研究需要能够有效处理异构性的负荷建模手段和扩展效率高的负荷调控方法。

1.2　灵活性发掘：细粒度耦合

AI训练任务的高算力密度与推理任务的高并发请求特性，推动了算力设备高功率密度的演进方向。智算中心单机柜功率从传统数据中心的10 kW以下跃升至40～120 kW，引发了严峻的可靠性挑

中国知网　https://www.cnki.net

战：一是局部过热问题出现的概率升高，位于同一智算中心的GPU之间温差可超过20 ℃[31-32]，易引发任务失败和设备故障甚至损坏；二是集中式备电发生故障时影响范围大[33-34]，在供电失效的条件下，备电一旦出问题，整个数据中心都将失去电力供应，导致大量高价值业务数据丢失或处理中断。为保障可靠性，制冷与备电设备均下沉至机架级乃至服务器级，如板级制冷和分布式蓄电池组等[35-36]。如图2所示，这一架构变化使得温控与储能单元在物理空间上与服务器耦合更紧密，导致多能交互的控制粒度从宏观的机房级细化至机架层级。

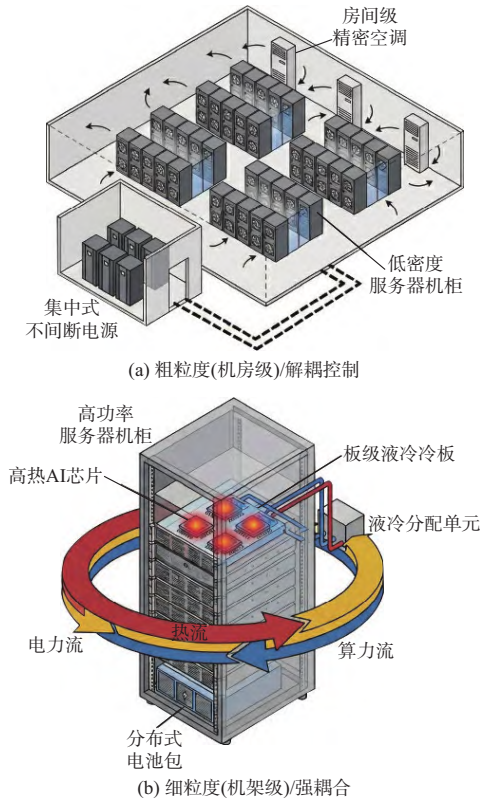


图2　智算中心设备的细粒度多能耦合
Fig. 2　Fine-grained multi-energy coupling of devices in intelligent computing center

更细粒度的多能耦合意味着部分灵活性资源呈现碎片化分布的特征，不同能源属性的设备之间彼此存在更紧密的运行制约。例如，计算任务的空间排布可能影响智算中心级的功耗特性，以及液冷系统和分布式储能设备的整体灵活性潜力等。传统根据设备功能进行划分，并在同一设备内部进行负荷灵活性聚合的思路可能不再适用。因此，需要深入研究空间细粒度的多能耦合效应，提出感知细粒度算力与热力约束下的灵活性聚合与评估方法。

1.3 灵活性利用：多主体协同

单个智算中心的运行优化涉及租户、运营方、电网等多个利益相关主体，如图3所示，其首要目标并不完全匹配，且存在固有的信息壁垒。即使对于租户自建并运营智算中心的特殊情况，同样会面临跨部门多目标的协调挑战：一方面，存在多个方面的全局优化目标，包括追求经济效益优化的计算资源利用率提升、追求用户体验优化的可靠性保障和响应企业社会职责的碳中和目标等；另一方面，算力编排与能量管理分属不同运营部门，现阶段AI算力芯片和承载业务的价值属性高于电价成本，算力侧与电力侧进行信息共享和协同运行的意愿较低。未来，伴随着算力互联互通和全国统一电力市场的持续推进，智算中心与电网互动的模式具备多样化发展的潜力，从单一数据中心、单并网点、单一电网需求逐步向智算集群、多并网点、多维度电网需求等方面转变，引入多类型用户、多算力企业和多省区电网，进一步加剧利益协调的挑战。

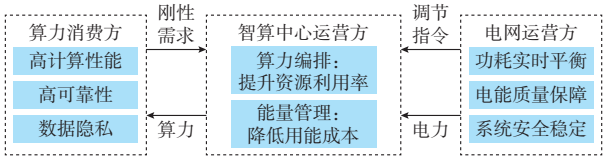


图3　智算中心运行优化涉及的多个利益主体
Fig. 3　Multiple stakeholders involved in operation optimization of intelligent computing center

因此，需要深入研究多主体利益的动态权衡方案与激励机制设计，并拓展至智算集群与电网多样化互动场景，实现灵活性的利益驱动与潜力释放。

2　国内外研究现状

本章按照负荷灵活性的研究问题进行拆分，依次从负荷建模、灵活性发掘、灵活性利用3个子问题进行展开。

2.1　负荷建模

精准的负荷模型是使灵活性发掘满足现实情况、使灵活性利用达成预设目标的前提，构成了灵活性研究的基础。本节按智算中心设备与业务耦合程度进行横向拆分，分别立足IT设备、制冷设备、备电及辅助能源设备3类主要设备。

2.1.1　IT设备

IT设备是智算中心能耗的主要来源，其中，AI专用芯片则是重中之重。以英伟达B200和A100服务器为例，GPU功耗约占总服务器功耗的2/3[22,37]。面向GPU或AI计算任务的功耗分析，主要有量测和建模两种形式：前者通过设备内部或外部加装的功率量测器件，直接提供IT设备的精确功耗值，适用于能效评估和模型验证；后者通过机理分析和量

中国知网　https://www.cnki.net

测数据构建软硬件运行参数与功耗之间的数学表达式，适用于功耗预测和灵活性量化。

面向GPU的功耗分析研究非常丰富，基于量测的功耗建模思路较为成熟，分为组件拆分和指令拆分两种。组件拆分是现有研究的主流[38]，基本思路是先构建微基准测试集，每个基准测试集侧重使用GPU中的不同组件，然后通过实测收集大量原始数据，进而获取各组件在一定时间单元内的动态能耗。文献[39-40]将性能计数器的计数作为输入，经拟合得到功耗模型，隐含了对GPU架构的组件拆解。文献[41]基于电子电路功耗的解析模型，进一步考虑了频率缩放引发的非线性电压变化，构建了GPU内存和核心多域频率变化下的GPU功耗模型。文献[42]提出了更为精细化的恒定功耗和静态功耗模型，前者考虑了动态电压频率调整(dynamical voltage and frequency scaling，DVFS)的影响，后者考虑了功耗门控和线程束分化的影响。相较于组件拆分，指令拆分的核心思路差异在于，最终构建的是不同类型指令在执行周期内的能耗[43]。这两种思路都要获取运行程序的细粒度执行信息，前者是基于仿真[44]或实测的硬件组件访问次数，后者是基于编译的指令类型数量。

面向AI计算任务的功耗分析研究，目前较多采用量测的形式，初步揭示功耗的影响要素和变化趋势。文献[45]分析了模型、任务、提示词和系统配置相关因素对LLM推理能耗的影响，揭示了推理能耗与输出长度和响应时间的强相关性，以及量化、批大小优化、提示词工程在能耗削减方面的显著效果。文献[46]探索了LLM推理功耗与输入长度、输出长度、批大小的关联关系，并且分析了功耗封顶和频率封顶对不同类型LLM模型训练功耗的影响。

面向AI计算任务的功耗建模研究逐渐受到关注，其主要沿袭GPU功耗建模的思路，但在泛化能力和准确性上仍有提升空间。文献[47]在文献[41]的基础上，构建了AI训练任务能耗关于本地批大小和GPU核心频率的数学模型，由梯度计算和通信同步两个过程的动态功耗以及静态功耗叠加而成。考虑到AI模型中计算子单元受DVFS的差异化功耗影响，文献[48]面向昇腾NPU构建了AI算子级别的功耗模型，尤其是引入了泄漏电流受温度的影响，提升了建模精确度。为刻画用能行为的动态特性，文献[49]将AI训练任务的GPU使用率建模为周期性脉冲序列，再通过线性映射得到瞬时功耗；进一步考虑实际执行过程中的不稳定性，文献[50]融合贝叶斯优化和神经网络的方法，从历史数据中发掘多时间尺度特性，实现AI计算任务负荷曲线预测。然而，所提模型难以直接适配多种异构AI模型和多种AI专用芯片，泛化能力较低。此外，由于尚未考虑其他IT设备，应用于智算中心级负荷预测时可能带来较明显的误差。文献[14]深入分析了数据中心内各IT设备功耗模型，但并未涉及计算任务到模型输入参数的映射关系。面向GPU或AI计算任务的功耗建模总结如表2所示。表中：c_i为组件i在单位时间的计数；u_i^d和f_d分别为第d个频率域中组件i的利用率和频率；$n_{i'}^{\mathrm{cmp}}$为第i'类计算指令数；$n_{j'}^{\mathrm{mem}}$为第j'类内存事务数；n为停顿次数；T为执行时间；n_i^{acc}为组件i的访问次数；n^{lane}为每个活跃流处理器中的活跃通道数；$n_{\mathrm{act}}^{\mathrm{sm}}$、$n_{\mathrm{idle}}^{\mathrm{sm}}$分别为活跃和不活跃流处理器的数量；$b$为本地批大小；$f$为计算芯片的频率；$V$为计算芯片的电压；$P$为功耗；$\alpha_i$和$P_0$为拟合参数；$\theta^{\mathrm{nn}}$为神经网络参数；$F\{\cdot\}$为神经网络函数；$\alpha_d$、$\beta_d$、$\omega_i^d$和$V_d$为拟合参数；$e_{i'}^{\mathrm{cmp}}$为执行一次第$i'$类计算指令的能耗；$e_{j'}^{\mathrm{mem}}$为执行一次第$j'$类内存事务的能耗；$e$为执行一次停顿的能耗；$P_{\mathrm{idle}}$为闲置功率；$e_i$为访问一次组件$i$的能耗；$p_{\mathrm{idle}}^{\mathrm{sm}}$为每个不活跃流处理器的闲置功率；$P_{\mathrm{const}}$为每个不活跃流处理器的常值功率；$P_{\mathrm{act}}^{\mathrm{sm}}(\cdot)$为关于$n^{\mathrm{lane}}$的一次函数；$P^{\mathrm{grad}}$为计算阶段功耗；$P^{\mathrm{sync}}$为同步阶段功耗；$P^{\mathrm{stat}}$为静态功耗；$\kappa_{\mathrm{g}}$、$\alpha_{\mathrm{g}}$、$\beta_{\mathrm{g}}$、$\gamma_{\mathrm{g}}$、$\alpha_{\mathrm{s}}$、$\beta_{\mathrm{s}}$、$\gamma_{\mathrm{s}}$、$\kappa_{\mathrm{s}}$、$\alpha_t$、$\beta_t$为拟合参数；$P_{\mathrm{op}}$为算子功耗；$\alpha_{\mathrm{op}}$为算子参数；$\theta$、$\gamma_t$、$k_t$为硬件相关参数。AI计算任务可以拆分为若干算子，每个算子一般对应一个GPU核函数，GPU核函数在执行时会首先编译为并行线程执行(parallel thread execution，PTX)指令，然后再转化为可被特定设备识别的机器码。

为了实现对计算性能的可控影响，在功耗建模以外往往同时进行性能建模，输入参数与功耗模型基本一致，输出参数为给定划分粒度下单位任务完成时间或吞吐率，采用方法包括基于时间线分析的机理建模、基于仿真[44]或实测信息的数据拟合等。

2.1.2　制冷设备

制冷设备是智算中心能耗的组成部分。为应对AI任务的高能耗密度引发的计算性能下降[52]和设备故障问题[22]，智算中心多采用制冷效率更高的液冷技术替代传统风冷技术[53]，或采用液冷为主、风冷为辅的过渡方案[54-55]。根据冷却介质与热源的接触方式，液冷技术具体可分为冷板式、单/双相浸没式、喷淋式3种。

面向液冷系统的建模研究主要聚焦于热力和水力模型[53]，较少同时考虑设备的电力需求。文献[56]在实验室工况中探索了单相浸没式液冷技术的冷却性能和能效，调节的系统参数为冷却液流向/流速和冷却水温度。文献[57]在仿真环境中研究了

中国知网　https://www.cnki.net

表2　面向GPU或AI计算任务的功耗建模总结

Table 2　Summary of power consumption modeling targeted at GPU applications or AI computing tasks

任务粒度	设备（型号）	输入变量	功耗模型	参数获取方法	来源
GPU核函数	GPU (NVIDIA GeForce GTX 285)	c_i	$P=\sum_i \alpha_i c_i + P_0$	岭回归	[39]
GPU核函数	GPU (NVIDIA Fermi C2075, M2090)	c_i	$P=F\{\{c_i\};\theta^{\mathrm{nn}}\}$	神经网络训练	[40]
GPU核函数	GPU (NVIDIA Titan Xp, GTX Titan X and Tesla K40)	u_i^d、f_d	$P=\sum_d\left[\alpha_d V_d + V_d^2 f_d\left(\sum_i \omega_i^d u_i^d + \beta_d\right)\right]$	迭代最小二乘法	[41, 51]
PTX指令、GPU核函数	GPU (NVIDIA Tesla K40)	n_i^{cmp}、n_j^{mem}、n、T	$P=\frac{1}{T}\left(\sum_i n_i^{\mathrm{cmp}} e_i^{\mathrm{cmp}} + \sum_j n_j^{\mathrm{mem}} e_j^{\mathrm{mem}} + ne\right) + P_{\mathrm{idle}}$	多次测量取平均	[43]
GPU核函数	GPU (NVIDIA Volta GV100, Pascal Titan X, Turing RTX 2060S)	n_i^{acc}、n^{lane}、$n_{\mathrm{act}}^{\mathrm{sm}}$、$n_{\mathrm{idle}}^{\mathrm{sm}}$、$T$	$P=\sum_i \frac{n_i^{\mathrm{acc}} e_i}{T} + P_{\mathrm{act}}^{\mathrm{sm}}(n^{\mathrm{lane}}) n_{\mathrm{act}}^{\mathrm{sm}} + p_{\mathrm{idle}}^{\mathrm{sm}} n_{\mathrm{idle}}^{\mathrm{sm}} + P_{\mathrm{const}}$	分层参数辨识（曲线拟合、几何平均、二次规划等）	[42]
AI训练任务阶段	GPU (NVIDIA A100)	b、f	$P^{\mathrm{grad}}=\kappa_{\mathrm{g}}(\alpha_{\mathrm{g}}\lg(b+\beta_{\mathrm{g}})+\gamma_{\mathrm{g}})$ $P^{\mathrm{sync}}=\alpha_{\mathrm{s}} f^3+\beta_{\mathrm{s}} f^2+\gamma_{\mathrm{s}} f+\kappa_{\mathrm{s}}$ $P^{\mathrm{stat}}=\alpha_t f+\beta_t$	非线性回归	[47]
AI算子	NPU (Huawei Ascend)	V、f	$P_{\mathrm{op}}=\alpha_{\mathrm{op}} f V^2+\gamma_t k_t P_{\mathrm{op}} V+\beta_t f V^2+\theta V$	分层参数辨识（联立求解、迭代求解等）	[48]

IT负载率和调度算法对液冷数据中心热调控和能效的影响，同时考虑了稳态和动态计算负载两类场景。然而，这些研究均是面向物理系统或仿真系统展开的量化分析，未构建系统功耗的数学模型。文献[58]基于元件传热特性，构建了冷板式液冷系统的功耗与芯片温度模型，其中，输入参数为芯片功耗、环境温湿度、一/二次侧泵头及冷却塔中介质体积流量。

2.1.3　备电及辅助能源设备

备电及辅助能源设备是智算中心天然的灵活性资源，按照用能行为特性，可具体分为3类：备用机组、储能、蓄冷/热。这部分基础设施由于与算力业务的耦合性较弱，和通算数据中心相似，各设备负荷模型已有大量研究[17,59]；主要的差异性来源包括：受绿色性要求驱动，燃料电池作为备用机组的清洁替代方案得到更广泛关注[60]；受高功率密度对可靠性要求的驱动，储能趋于下沉至机架级且超级电容器等高功耗响应器件的应用比例提升[36,61]。虽然智算中心与通算数据中心存在供配电结构上的差异，但涉及的设备并非新兴。文献[62]提出了氢燃料电池与新能源的多种集成场景，利用HOMER软件进行了多时间尺度运行模拟。文献[63]系统性地构建了数据中心多种储能装置在功耗曲线调节方面的成本效益模型和多供电层级混合部署下的时序运行模型。文献[64]构建了潜热储能的两种相变传热模型，开展了热性能的数值分析及对比。

2.2　灵活性发掘

本节从2.1节涉及的IT设备、制冷设备、备电及辅助能源设备3类主要设备出发，按所发掘灵活性的时空维度进行分类，分别归纳各设备的功耗调节手段，总结如图4所示。调控能力指的是不同调控手段下，灵活性资源在智算中心聚合后产生的负荷可变范围。图4中，圆形的面积可以定性反映调控能力的大小。

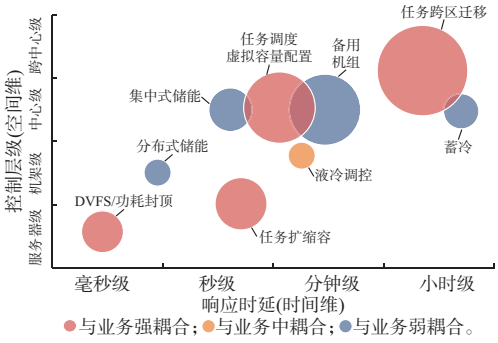


图4　智算中心负荷灵活性发掘手段总结

Fig. 4　Summary of methods for identifying load flexibility in intelligent computing center

2.2.1　时间维灵活性

IT设备的时间维负荷灵活性，本质上来源于任务执行速率的可调性，既包括单台设备的执行速度，也包括任务在集群中的并行执行规模。其基本逻辑在于：一方面，设备功耗通常与任务执行速率正相关；另一方面，部分任务的完成时间具有一定的松弛空间。因此，从调控机理上看，时间维负荷灵活性大体可分为两种方法：一种方法直接改变设备的峰值计算性能；另一种方法改变承载任务的设备数量。

第1种方法直接作用于设备性能上限，典型代

中国知网　https://www.cnki.net

表包括设备级DVFS和功耗封顶。这类方法的优势在于响应速度快、持续时间灵活:其在物理设备上的调节响应可达到微秒甚至纳秒级[48,65],且原则上可维持任意时长,但其实际功耗调节幅度及相应的性能损失并不由控制指令单独决定,而是同时受任务特性约束。文献[66]提出了一种对应用透明的在线GPU频率调节方案,基于GPU内存利用率和计算性能之间存在线性关联的核心发现,无须运行应用的任务细节即可在动态调节功率的同时预测改变后的计算性能。文献[67]在高性能计算中心的尺度上测试了功率封顶对计算性能和温度的影响,揭示了功率封顶对计算性能影响较小,能够提升硬件可靠性和使用寿命。需要注意的是,功率门控是一种芯片内部硬件自动执行的电源管理技术,虽然能够在性能不变的条件下显著降低功耗[68],但由于并未提供对外功能接口而无法自定义调整。

第2种方法通过改变承载任务的设备数量来调节集群级功耗水平,包括容量配置、任务调度与任务级弹性扩缩容。容量配置通过设置可用设备数量上限而约束集群功耗峰值,其特点是实现简单、控制粒度粗,不直接干预任务执行顺序。因此,该方法适合形成集群功耗的上边界,但难以精确控制实际运行设备数和功耗水平。文献[69]针对电网动态碳排放强度信号,基于日前电力及计算任务的预测,通过风险感知的优化方法生成可推迟任务的日前虚拟容量曲线。与之相比,任务调度通过改变任务的启停时刻,相对精确地调整每一时刻运行设备的总数,而任务级弹性扩缩容则进一步改变分配给单个任务的设备数。文献[70]提出了数据驱动的灵活性评估方案,量化周期性批处理任务由时序推迟产生的调节潜力,并考虑了任务到达模式和任务间依赖关系;在此基础上,文献[71]提升了负荷灵活性模型与电网调度运行的兼容能力。

现有围绕第2种方法的代表性研究仍以通算任务为主,其灵活性发掘的思路对其他类型任务具备参考价值,但是具体建模和实现方法难以直接迁移到AI计算任务中,主要原因可归纳为以下3个方面。1)通过聚类等方法削减任务维度,通常依赖任务呈现出较稳定、可归并的资源使用模式;而AI计算任务则不同,往往表现为小任务很多,但真正决定集群总负荷的是少数大任务[30,72],故难以用少量代表性任务刻画整体任务集合。2)AI任务到功耗的映射关系更加复杂,对于在CPU上执行的通算任务,任务计算量、CPU利用率和CPU功耗两两之间常用线性关系来近似刻画[18]。由2.1.1节可知,GPU功耗模型包含了多个输入参数,最简单的情况也采用了计算和内存两类组件的利用率作为输入参数。3)任务调度的时效追求不仅仅表现为确定性的时限约束。在任务调度的传统研究中,优化目标常聚焦于集群级的计算性能指标(如固定任务集合下的完成时间[73]),故对于资源稀缺的AI计算任务,集群在时效方面的目标和功耗调控的目标是同等重要的。

更为适配AI计算任务的研究则从贴近真实调度逻辑的场景出发,在此基础上发掘时间维度上的负荷灵活性。文献[74]考虑了任务在执行时长和资源需求方面的异构性,通过强化学习实时调节负荷曲线。文献[75]提出了一种预测和利用任务级能耗信息实现系统级功耗封顶的资源管理方法。为提升实用性,文献[76]提出了无须修改Slurm核心调度器即可开发、评估和实现能耗感知调度的系统应用方案,其中,通过基于LLM的脚本分析进行任务级功耗预测。文献[77]发掘了任务时序调度所能实现的GPU集群负荷灵活性,通过启发式规则实现不影响任务完成时限下的集群碳排放削减。采用相同的调控手段,文献[78]利用强化学习技术生成调度策略,刻画了碳排放与服务质量的帕累托前沿。

这类基于真实任务调度逻辑的研究,对前述3个方面适配性问题的应对思路主要体现在以下3个方面:1)不压缩任务维度,直接面向原始任务集开展决策,但由于调度问题本身的非确定性多项式(NP)难属性[79],通常借助启发式规则[80]或强化学习尽可能逼近理论最优;2)采用数据驱动或直接量测的方法获取从任务到功耗的复杂映射;3)同时探索调度策略对功耗调控和时效性两方面的影响。

需要指出的是,第1个方面的应对思路虽然对任务的刻画更加准确,但通常未显式给出灵活性的大小和边界;第2个方面的应对思路依赖于较充分的历史观测数据,或要求能够对新任务进行低开销的试运行,应用于大型且异构性强的AI训练任务时效果未必显著。此外,这些研究对AI计算任务在资源使用上的特殊性仍有进一步的拓展空间,包括但不限于:AI任务在进行弹性扩缩容的同时往往需要修改并行策略,即使是最简单的数据并行,扩充数量后由于跨设备同步的通信量和相应时延变大,计算性能并非线性变化[81]。同样,由于AI任务同步过程的存在,给AI计算任务分配相同型号但位于集群中不同位置的设备时,只要设备间实际通信能力存在差异(如通信带宽和通信链路的繁忙程度),计算性能和功耗就会发生变化[47,82-83]。

将AI计算任务运行特性纳入时间维灵活性发掘的研究目前仍较为有限,仅有少量能耗感知的AI

中国知网　https://www.cnki.net

任务调度工作，结合上述两类方法，验证了功耗的动态调整能力。文献[84]从数据和张量两个维度将大型AI训练任务拆解为若干子任务后再进行调度，本质上是任务级扩缩容的一种具体实现机制。文献[47]则进一步将设备级DVFS与任务级扩缩容、集群级调度的调控手段相结合，提出了能在给定碳排放预算下优化任务完成时间的GPU集群调度器，并考虑了任务放置过程中忽略GPU通信距离差异导致的资源碎片化问题。以上文献主要考虑的是训练任务，也有针对推理任务的研究。文献[10]动态且自动地配置LLM推理服务系统参数，包括实例数量、模型并行策略和GPU频率，在满足服务等级目标（service level objective，SLO）的前提下调整系统用能行为。为协调训推一体环境下两类计算任务的资源使用，文献[81]利用推理任务时序波动产生的冗余设备对微调任务进行弹性扩充，在两类任务计算性能均不变的条件下，发掘了智算中心算力负荷的分钟级灵活性。

制冷设备的时间维灵活性主要通过改变对流热量来实现，基本原理是散热量和电力消耗的正相关关系，以及制冷介质的热惯性。面向风冷和液冷数据中心的热管理研究较为成熟[16]，并有部分工作探索了利用建筑内部空气的热惯性进行暖通电力负荷调控以响应动态价格信号的场景[85-86]，但对液冷设备进行电力调控的工作近期才开始出现。文献[58]提出了针对液冷系统中冷却塔风量、一/二次流速等运行参数的小时级实时优化方法，以在芯片温度的约束下最小化系统能耗，但并未考虑机架级多能耦合下的细调控粒度。

备电及辅助能源设备的时间维灵活性主要通过电能和其他种类能源的转换实现：备用机组提供上调能力、储能设备提供双向调节能力、蓄冷设备间接提供功耗调节能力。文献[87]试验性地部署了机架级燃料电池，验证了氢燃料电池的秒级响应速度。文献[13]发掘了通信高压直流电源侧储备一体电池的日内闲置灵活性，通过可感知算力需求的充放电策略，对内提升算力承载能力，对外提供需求响应能力。文献[88]基于所设计的热能储存系统，分析了该系统的季节性灵活调节潜力，通过冬季储存天然冷资源以降低夏季的制冷负荷。

以上各调节手段下智算中心时间维灵活性的特征如表3所示。表中：P_R为设备额定功率；n_{min}为最小设备数；n_{max}为最大设备数；N为总设备数；P_{min}为设备最低功率；E_{cool}为蓄冷容量；η为制冷效率。

表3　不同调节手段下智算中心负荷时间维灵活性的特征

Table 3　Characteristics of temporal load flexibility of intelligent computing center under various regulation measures

与业务耦合程度	来源	调节手段	供电层级	最大调节范围	调节粒度	调节精度	响应时延	最长可持续时间
高	IT设备	DVFS[48,66]	服务器级	$[P_{idle},P_R]$	离散	高	微秒-毫秒级	不限，但受SLO间接约束
		功耗封顶[67]	服务器级	$[P_{idle},P_R]$	连续	中	微秒-毫秒级	不限，但受SLO间接约束
		任务扩缩容[47,77,81,89]	服务器-机架级	$[n_{min}P_R,n_{max}P_R]$	离散	中	秒-分钟级	任务执行时长，另受SLO约束
		容量配置[69]	中心级	$[0,NP_R]$	离散	低	秒-分钟级	不限，但受SLO间接约束
		任务调度[77,89]	中心级	$[0,NP_R]$	离散	中	秒-分钟级	受任务执行时长和SLO间接约束
中	液冷系统	介质流量调控[58,90]	机架-中心级	$[P_{min},P_R]$	连续	高	秒-分钟级	不限，但受热安全约束
低	备用机组	发电[59]	中心级	$[-P_R,0]$	连续	高	秒-分钟级	不限
	锂电池	充/放电[13,63]	机架-中心级	$[-P_R,P_R]$	连续	高	毫秒-秒级	设备容量/额定功率
	蓄冷设备	蓄/释冷[88,91]	中心级	$[-E_{cool}/\eta,0]$	连续	低	分钟-天级	蓄冷容量/释冷速率

2.2.2　空间维灵活性

空间维灵活性主要存在于IT设备负荷中，其基本原理是在地理位置不同的计算集群之间对计算任务进行重新部署。按照调控发生的时间点，可进一步分为两类：一类是分配，在任务开始前确定其执行的集群；另一类是迁移，在任务开始执行后改变其所在的集群。

对于在线请求而言，执行时间短且时延要求高，多采用排队模型刻画执行过程[92]，并且主要通过请求流量在不同集群间的分配来实现空间调节，不涉及单个任务粒度的迁移。文献[93]提出了一种地理负荷均衡的通用架构与分布式求解算法，结合了请求流量分配和容量配置，从而提供时段间解耦的小时级稳态功耗塑造能力。对于批处理任务而言，执行时长相对较长且时延要求较低，因而既可以在开始前进行跨集群分配，也可以在执行过程中进行迁移，以实现更灵活的部署。文献[94]基于现实中广泛部署的容器编排器Kubernetes开发了低碳调度的功能，按照数据中心接入电网的碳排放强度和气温进行排序以确定任务的部署位置。文献[95]考虑了

中国知网　https://www.cnki.net

子任务间存在的先后次序关系，采用强化学习实现任务迁移与资源分配方案的快速生成。

相较于时间维灵活性，空间维灵活性发掘需要额外关注跨区部署的代价，主要体现为通信时延或能耗增量[96]。在已有的通算研究中，主要关注任务传输数据量相同的场景，故一般将部署代价刻画为任务数量的正比例项，比例系数为定值或由迁移所经通信链路决定的常数。在跨不同利益主体所属数据中心协同中，跨区部署的代价还包括敏感信息泄露，如任务粒度的资源配置信息，因而分布式算法、联邦学习、同态加密等隐私保护技术逐渐被引入[95,97]。

与时间维灵活性类似，空间维灵活性研究目前也以通算任务为主，对AI计算任务具备思路上的借鉴价值，但并不能完全适用，原因除了2.2.1节中阐述的部分外，还包括以下内容。对于AI训练任务，难以直接用任务数的线性相关项刻画通信代价，因为每个训练任务所需样本数据量和迁移所需模型信息量都可能不同，会带来差异化的传输时延；对于超大型训练任务，迁移的对象可能不再是单个任务，而是多个需要同步执行的子任务。对于具备自回归特性的LLM推理任务，通算研究中的简单排队模型难以准确刻画其执行过程。这是由于每个推理请求本质上由若干个数量不定且先后执行的子任务组成，一个推理实例（指能够独立响应推理请求的最小单元，可能由多台服务器组成）可以同时执行多个不同请求的子任务，完成时间与请求数量、输入长度、执行阶段（预填充和解码）均有关[98]，不再满足通算研究中任务独占执行单元以及任务的执行时间满足独立同分布的假设条件。

目前，面向AI计算任务的空间维灵活性研究仍处于起步阶段。虽然业界已开发智算集群的全球广域任务调度系统，验证了跨集群任务部署的技术可行性，但面向电力负荷空间灵活性的研究仍不充分。文献[99]发布了微软面向深度学习训练和推理工作负载的全球分布式调度服务，通过对深度学习负载的透明式抢占、迁移和扩缩容，在可忽略稳态性能影响的条件下大幅提升任务的时空灵活调度能力。在Meta集群管理系统的基础上，文献[100]研究了大规模AI训练任务的全局调度问题，采用时间解耦、范围解耦、遍历搜索的组合思路突破数据中GPU同址部署和可扩展性的挑战，但尚未明确纳入能耗感知的功能。

2.3　灵活性利用

本节分析智算中心负荷灵活性的应用场景，归纳不同时空尺度灵活性的利用方案。

1）内部运行可靠性

文献[31]提出了专为云LLM推理集群设计的功耗和热感知调度框架，利用多种配置参数下虚拟机温度与功耗的差异化特性，进行覆盖毫秒至周时间尺度的虚拟机配置、推理负载路由和虚拟机放置，以加强冷却和电力超额订阅能力，降低运行故障率。

2）低碳发展与可持续性

一部分工作通过降低整体能耗实现碳减排。文献[10]利用推理计算在预填充和解码阶段的异构性和推理负载的波动性，通过设备级、任务级和集群级调控手段的协同作用，实现了LLM推理服务系统的能效提升。文献[101]结合设备级和任务级调控手段，发现了深度神经网络训练任务在能耗和时长上的权衡关系，提出了一种通过探索利用和能耗测算优化能效的实时调控策略。

另一部分工作通过响应电网碳排放强度的时序变化实现碳减排。文献[47,77,102]追随电网小时级碳排放强度因子的变化，利用计算任务的松弛时限要求和多种调控手段，在尽可能降低对任务完成时间的性能损耗下最小化总运营碳排放。考虑自建机组的场景，文献[103-104]提出了计及负荷灵活性的电源侧容量优化方案。

3）电网互动友好性

为解决AI训练任务由于计算和通信环节迭代切换引发的亚秒级功耗波动，文献[37]结合了基于毫秒级功耗监测的次要任务注入、GPU内置的功率平滑功能、机柜级储能设备，使得训练任务负荷特性能够满足电网时域和频域要求，避免引发电网次同步谐振等稳定性问题。

除了消弭对电网造成的潜在风险，也有工作探索了智算中心利用负荷灵活性参与电网需求响应这一场景下的潜力。Emerald AI通过协调任务级与服务器级的时间维灵活性，分别在美国和英国的智算中心，基于小规模研究资源开展了负荷灵活性的测试，实现了25%[89]和30%[105]的功耗调节比例。此外，已有大量研究探索了单一通算数据中心在被动和主动参与需求响应项目中的灵活性利用方案[106-107]，并拓展到了多个地理分布数据中心的场景[17,108-109]。为体现需求响应所涉及各主体的利益诉求，文献[110]探索了多电力运营商竞争定价与单算力运营商协调跨区数据中心的收益均衡；同为主从博弈框架，文献[111]则研究了单一电力运营商为多个独立运营数据中心定价的场景，并将单次响应拓展到日前和日内的多个时间尺度。为协调需求响应所涉及各主体的利益，文献[108]在电力批发市场环境下设计了多数据中心的需求响应机制激活策略

中国知网　https://www.cnki.net

和收益再分配机制，实现输电网与各数据中心的激励相容；文献[112]则在配电网尺度下，通过算力租赁机制的引入，实现配电网和数据中心的协同，进而拓展到与配水网的耦合[113]。此类研究为智算中心灵活性应用提供了参与电网需求响应的互动思路与分析框架，但并未揭示智算中心高价值业务属性下现有机制的有效性，以及算力市场形成后与电力市场的广域互动方案。

3　研究展望

结合第1章的挑战分析和第2章的研究现状评述，本章总结并展望了智算中心灵活性研究的未来方向，并分析了潜在的技术解决方案。

3.1　适应多维度异构的任务级负荷建模

智算中心负荷建模是灵活性刻画和应用的重要基础，AI计算任务作为智算中心的服务对象，其负荷模型成为灵活性研究的核心前提。由于计算过程的软硬件多维度异构特性，AI计算任务间表现出差异化的用能行为和计算性能，以及相同调节手段下对功耗和性能的差异化影响。同时，现有研究面向AI计算任务的功耗研究在测算和建模方面虽有初步探索，但在泛化能力和准确度上仍有待提升。因此，智算中心负荷建模需要构筑从芯片层级到系统层级之间的连接桥梁，构建适应多维度异构的任务级负荷模型，形成高准确度的功耗基准库。

针对泛化能力的问题，存在两个方向的解决思路。第1种思路，类比线性代数中的基底向量，将AI计算任务拆解为若干基础算子，在已知基础算子功耗的条件下即可得到任务功耗。具体而言，首先，提取主流AI模型结构的组成部分，根据基于访存比的特性分析或基于聚类的分类手段，形成可组成任意模型结构的基础算子库；然后，基于GPU建模中组件拆分的思路，设计微基准测试集，构建基础算子在特定设备执行时的功耗表；最后，考虑结合计算图拓扑、算子融合、并行策略的分析，实现AI计算任务的精细化功耗预测。第2种思路，构建以通用调控手段为输入的功耗模型表达式，利用AI任务的迭代特性，基于在线执行的数据得到模型的具体参数。除去已有研究考虑的设备频率之外，可行的调控手段还包括模型量化、并行策略等。第1种思路服务于集群级任务调度的灵活性发掘，第2种思路服务于设备级和任务级调节手段的灵活性发掘，两种思路可发挥互补作用。此外，还存在一种潜在的发展方向，即提升跨硬件泛化能力，面向同架构代际差异和架构差异，分别采用比例缩放和基于硬件结构表征的迁移学习机制；需要注意的是，由于硬件类别的数量远小于AI模型的数量，这一方向可以通过面向不同设备构建不同模型的方式解决。

针对准确度的问题，核心目标是构建以AI计算任务为核心、涵盖其他IT设备与制冷系统的总负荷模型。首先，在计算芯片功耗模型的基础上，研究不同任务组合下的通信负载与存储负载，构建涵盖计算、通信、存储的IT设备总负荷模型。其次，针对现有液冷研究较少考虑电力需求的不足，构建电热耦合下IT功耗到制冷功耗的传递关系，反向引入温度对泄漏电流的影响机制。最后，分析任务空间排布对总负荷的影响机理，提出考虑空间细粒度电热耦合效应的总负荷修正模型。

3.2　感知细粒度耦合的灵活性动态刻画

智算中心负荷灵活性的刻画，为灵活性应用提供可信边界，可分解为发掘和聚合两个关键子问题，前者提供灵活性资源组件，后者实现资源组件的组合。在灵活性发掘方面，现有研究对AI计算任务调度层面关注不够，空间灵活性的探索仍需加强。在灵活性聚合方面，由于智算中心存在细粒度多能耦合，灵活性资源呈现碎片化、紧耦合的特征，需要研究深度适配AI任务调度系统、感知细粒度算力-电力-热力耦合约束的灵活性量化与聚合方法。

针对灵活性发掘的问题，需要重点围绕相较于通算存在差异性的AI任务和液冷系统，拓展相关设备负荷灵活性的实现机理，并对可调能力进行量化表征。AI计算任务是智算中心的主要负荷来源，可从时空两个维度具体展开。在时间维方面，研究设备级、任务级、集群级多层级手段的协同方案和调节效果，实现任务负荷在各时间尺度上的灵活性潜力提升。在空间维方面，研究基于通信网络拓扑和任务特性感知的时延建模，以及时延对计算性能的影响，面向推理和训练两大类AI任务分别展开研究：一方面，考虑LLM推理预填充与解码阶段的协同调度过程，研究LLM推理服务请求流量分配和跨区容量的策略表征；另一方面，分析不同数据备份与传输场景下训练任务跨区迁移或协同的可行性，与功耗模型相结合，刻画出不同电气及通信距离尺度下的负荷空间分布可行域，以及负荷可行点与调控成本的映射关系。进而，需要研究智算中心异质灵活资源的动态聚合方法。首先，研究细粒度耦合下多层级储能、液冷系统与任务调度的协同影响，构建面向不同时空尺度的外特性刻画能力；然后，研究智算中心灵活性的实时量化方法，实现基于系统状态和任务预测的灵活性动态特性在线评估；最后，构建任务到达模式和资源需求等任务级特征不确定性的概率模型，实现智算中心灵活性资源的鲁棒聚合。

中国知网　https://www.cnki.net

3.3　激励多主体协同的灵活性拓展应用

智算中心灵活性的应用是灵活性发掘的主要目标,也是提升算电耦合系统综合效益的直接手段。现有研究主要站在单体智算中心运营的角度分别优化运行可靠性、可持续性和电网互动友好性,简化了内部的多利益主体协调问题。未来,在全国统一电力市场与算力互联互通的建设框架下,智算集群与电网在不同时空尺度互动产生多样化场景,多利益主体协同挑战更加突出。因此,需要深入研究智算中心与智算集群运行多优化目标的动态权衡,设计适配智算集群与电网多样化互动模式的激励机制,通过利益驱动打破协同壁垒,充分释放灵活性应用潜力。

具体而言,在多目标协调方面,构建统一价值量化下的算力与电力调度多维指标体系,表征灵活性潜力与核心指标的关联关系;分析指标间的耦合强度和权衡空间,面向多样化互动场景,提出智算中心灵活性的层次化利用方案;研究基于LLM、强化学习等技术的算力-电力在线协同调度方法,设计有限信息交互下的分布式控制架构,支撑用能行为的精确塑造。在激励机制方面,考虑智算中心业务的高价值属性和业务需求的强不确定性,设计针对性的电力市场激励机制,拓展智算中心负荷灵活性产品形式,例如,在极端天气、瞬时大扰动等非常规情况下支撑电网安全性的辅助服务,从而提升智算中心与电网友好互动的积极性,在共赢中释放智算负荷灵活性价值。

4　结语

智算中心负荷灵活性是缓解AI碳减排压力的重要资源,是实现算电协同优化的关键手段。然而,目前国内外数据中心灵活性研究主要面向的是通算数据中心,研究成果难以直接迁移至智算中心的场景。基于AI计算任务的特性分析,智算中心负荷灵活性研究主要面临多维度异构、细粒度耦合和多主体协同3个方面的挑战。因此,需要攻克智算中心负荷灵活性的关键技术:1)适应多维度异构的任务级负荷建模;2)感知细粒度耦合的灵活性动态刻画;3)激励多主体协同的灵活性拓展应用。

通过构建智算中心负荷灵活性的方法体系,突破任务调度和能量管理的无形壁垒,充分释放以AI计算任务为核心的时空调控潜力,有利于算力可持续发展并促进新能源高效消纳,为双碳目标下的算力-电力协同发展提供一条可行的实现路径。

参考文献

[1] De Vries A. The growing energy footprint of artificial intelligence [J]. Joule, 2023, 7(10): 2191-2194.

[2] Crawford K. Generative AI's environmental costs are soaring—and mostly secret[J]. Nature, 2024, 626(8000): 693.

[3] Kaplan J, Mccandlish S, Henighan T, et al. Scaling laws for neural language models[PP/OL]. [2026-01-21]. http://arxiv.org/abs/2001.08361.

[4] Li Y, Mughees M, Chen Y, et al. The unseen AI disruptions for power grids: LLM-induced transients[PP/OL]. [2026-01-21]. http://arxiv.org/abs/2409.11416.

[5] Electricity 2024[EB/OL]. [2026-01-21]. https://www.iea.org/reports/electricity-2024.

[6] Executive summary: energy and AI analysis[EB/OL]. [2026-01-21]. https://www.iea.org/reports/energy-and-ai/executive-summary.

[7] 国家能源局.2024年可再生能源并网运行情况[EB/OL].[2026-01-21].https://www.nea.gov.cn/20250221/e10f363cabe3458aaf78ba4558970054/c.html.
National Energy Administration. Renewable energy grid connection operations in 2024[EB/OL]. [2026-01-21]. https://www.nea.gov.cn/20250221/e10f363cabe3458aaf78ba4558970054/c.html.

[8] 国家发展和改革委员会.关于有序推动绿电直连发展有关事项的通知[EB/OL].[2026-01-21]. https://www.ndrc.gov.cn/xwdt/tzgg/202505/t20250530_1398139.html.
National Development and Reform Commission. Notice on matters concerning the orderly promotion of direct grid connection for green electricity[EB/OL]. [2026-01-21]. https://www.ndrc.gov.cn/xwdt/tzgg/202505/t20250530_1398139.html.

[9] Li J M, Xu H, Zhu Y B, et al. Lyra: elastic scheduling for deep learning clusters[C]// Proceedings of the Eighteenth European Conference on Computer Systems, 2023: 835-850.

[10] Stojkovic J, Zhang C J, Goiri Í, et al. DynamoLLM: designing LLM inference clusters for performance and energy efficiency[C]// 2025 IEEE International Symposium on High Performance Computer Architecture (HPCA), 2025: 1348-1362.

[11] Bennett C H. Notes on Landauer's principle, reversible computation, and Maxwell's Demon[J]. Studies in History and Philosophy of Science Part B: Studies in History and Philosophy of Modern Physics, 2003, 34(3): 501-510.

[12] Zhang Y W, Wang Y F, Wang X R. GreenWare: greening cloud-scale data centers to maximize the use of renewable energy [C]// 12th International Middleware Conference, 2011: 143-164.

[13] 陈敏,郭庆来,井汤博,等.算电协同探索:HVDC侧储备一体电池灵活性挖掘[J].电力建设,2025,46(2):1-12.
Chen Min, Guo Qinglai, Jing Tangbo, et al. Exploring synergy of computing power and electricity: unearthing flexibility of high-voltage direct current-side integrated backup and energy storage batteries[J]. Electric Power Construction, 2025, 46(2): 1-12.

中国知网　https://www.cnki.net

[14] Dayarathna M, Wen Y G, Fan R. Data center energy consumption modeling: a survey [J]. IEEE Communications Surveys & Tutorials, 2016, 18(1): 732-794.

[15] Huang H K, Lin W W, Lin J P, et al. Power management optimization for data centers: a power supply perspective [J]. IEEE Transactions on Sustainable Computing, 2025, 10(4): 784-803.

[16] Habibi Khalaj A, Halgamuge S K. A review on efficient thermal management of air- and liquid-cooled data centers: from chip to the cooling system [J]. Applied Energy, 2017, 205: 1165-1188.

[17] Chen M, Gao C W, Song M, et al. Internet data centers participating in demand response: a comprehensive review [J]. Renewable and Sustainable Energy Reviews, 2020, 117: 109466.

[18] Fan X B, Weber W D, Barroso L A. Power provisioning for a warehouse-sized computer [C]// Proceedings of the 34th Annual International Symposium on Computer Architecture, 2007: 13-23.

[19] Characteristics and risks of emerging large loads [EB/OL]. [2026-01-21]. https://www.nerc.com/comm/RSTCReview Items/3_Doc_White% 20Paper% 20Characteristics% 20and% 20Risks%20of%20Emerging%20Large%20Loads.pdf.

[20] Uptime institute global data center survey 2024 [R/OL]. 2024-07-30. https://datacenter.uptimeinstitute.com/rs/711-RIA-145/images/2024.GlobalDataCenterSurvey.Report.pdf.

[21] NVIDIA DGX GB rack scale systems user guide [EB/OL]. [2026-01-21]. https://docs.nvidia.com/dgx/dgxgb200-user-guide/hardware.html.

[22] Ludema J, Nossokoff M, Joseph E. Insights into liquid cooling in brownfield HPC and AI data centers [EB/OL]. [2026-01-21]. https://hyperionresearch.com/wp-content/uploads/2025/04/Hyperion-Research-Quick-Take-Liquid-Cooling-March-2025-1.pdf.

[23] Tadanobu K. Generative AI and data center related business [EB/OL]. [2026-01-21]. https://holdings.panasonic/global/corporate/investors/pdf/20241127_ai_e.pdf.

[24] 国家发展和改革委员会,工业和信息化部,国家能源局.数据中心绿色低碳发展专项行动计划[EB/OL].[2026-01-21]. https://www.gov.cn/zhengce/zhengceku/202407/P020240724272072479001.pdf.

National Development and Reform Commission, Ministry of Industry and Information Technology, National Energy Administration. Special action plan for green and low-carbon development of data centers [EB/OL]. [2026-01-21]. https://www.gov.cn/zhengce/zhengceku/202407/P020240724272072479001.pdf.

[25] 上海市经济和信息化委员会.上海市智算中心建设导则(2025年版)[EB/OL].[2026-01-21].http://www.sheitc.sh.gov.cn/cmsres/75/75a20d288e334260932b1aeaa36863c9/417aadec108d549cce53436579eec74a.pdf.

Shanghai Municipal Commission of Economy and Information Technology. Guidelines for the construction of the Shanghai intelligent computing center (2025 edition) [EB/OL]. [2026-01-21]. http://www.sheitc.sh.gov.cn/cmsres/75/75a20d288e334260932b1aeaa36863c9/417aadec108d549cce53436579eec74a.pdf.

[26] Lecun Y, Bengio Y, Hinton G. Deep learning [J]. Nature, 2015, 521(7553): 436-444.

[27] Models [EB/OL]. [2026-01-21]. https://huggingface.co/models.

[28] Kwon W, Li Z H, Zhuang S Y, et al. Efficient memory management for large language model serving with paged attention [C]// Proceedings of the 29th Symposium on Operating Systems Principles, 2023: 611-626.

[29] Agrawal A, Kedia N, Mohan J, et al. Vidur: a large-scale simulation framework for LLM inference [C]// Proceedings of Machine Learning and Systems, 2024: 351-366.

[30] Hu Q H, Ye Z S, Wang Z R, et al. Characterization of large language model development in the datacenter [C]// 21st USENIX Symposium on Networked Systems Design and Implementation, 2024: 709-729.

[31] Stojkovic J, Zhang C J, Goiri Í, et al. TAPAS: thermal- and power-aware scheduling for LLM inference in cloud platforms [C]// Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, 2025: 1266-1281.

[32] Cao Y, Wang H, Cao Y, et al. A task scheduling scheme for preventing temperature hotspot on GPU heterogeneous cluster [C]// International Conference on Green Informatics, 2017: 117-121.

[33] Malla S, Deng Q Y, Ebrahimzadeh Z, et al. Coordinated priority-aware charging of distributed batteries in oversubscribed data centers [C]// 2020 53rd Annual IEEE/ACM International Symposium on Microarchitecture (MICRO), 2020: 839-851.

[34] Kontorinis V, Zhang L E, Aksanli B, et al. Managing distributed ups energy for effective power capping in data centers [J]. ACM SIGARCH Computer Architecture News, 2012, 40(3): 488-499.

[35] Enabling 1 MW IT racks and liquid cooling at OCP EMEA Summit [EB/OL]. [2026-01-21]. https://cloud.google.com/blog/topics/systems/enabling-1-mw-it-racks-and-liquid-cooling-at-ocp-emea-summit.

[36] Building the 800 V DC ecosystem for efficient, scalable AI factories [EB/OL]. [2026-01-21]. https://developer.nvidia.com/blog/building-the-800-vdc-ecosystem-for-efficient-scalable-ai-factories/.

[37] Choukse E, Warrier B, Heath S, et al. Power stabilization for AI training datacenters [PP/OL]. [2026-01-21]. http://arxiv.org/abs/2508.14318.

[38] Bridges R A, Imam N, Mintz T M. Understanding GPU power: a survey of profiling, modeling, and simulation methods [J]. ACM Computing Surveys, 2017, 49(3): 1-27.

[39] Nagasaka H, Maruyama N, Nukada A, et al. Statistical power modeling of GPU kernels using performance counters [C]//

中国知网　https://www.cnki.net

International Conference on Green Computing, 2010: 115-122.
[40] Song S W, Su C Y, Rountree B, et al. A simplified and accurate model of power-performance efficiency on emergent GPU architectures [C]// 2013 IEEE 27th International Symposium on Parallel and Distributed Processing, 2013: 673-686.
[41] Guerreiro J, Ilic A, Roma N, et al. GPGPU power modeling for multi-domain voltage-frequency scaling [C]// 2018 IEEE International Symposium on High Performance Computer Architecture (HPCA), 2018: 789-800.
[42] Kandiah V, Peverelle S, Khairy M, et al. AccelWattch: a power modeling framework for modern GPUs [C]// MICRO-54: 54th Annual IEEE/ACM International Symposium on Microarchitecture, 2021: 738-753.
[43] Arunkumar A, Bolotin E, Nellans D, et al. Understanding the future of energy efficiency in multi-module GPUs [C]// 2019 IEEE International Symposium on High Performance Computer Architecture (HPCA), 2019: 519-532.
[44] Khairy M, Shen Z S, Aamodt T M, et al. Accel-sim: an extensible simulation framework for validated GPU modeling [C]// 2020 ACM/IEEE 47th Annual International Symposium on Computer Architecture (ISCA), 2020: 473-486.
[45] Poddar S, Koley P, Misra J, et al. Towards sustainable NLP: insights from benchmarking inference energy in large language models [C]// Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies, 2025: 12688-12704.
[46] Patel P, Choukse E, Zhang C J, et al. Characterizing power management opportunities for LLMs in the cloud [C]// Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, 2024: 207-222.
[47] Gu D D, Zhao Y H, Sun P, et al. GreenFlow: a carbon-efficient scheduler for deep learning workloads [J]. IEEE Transactions on Parallel and Distributed Systems, 2025, 36 (2): 168-184.
[48] Wang Z B, Zhang Y J, Wei F C, et al. Using analytical performance/power model and fine-grained DVFS to enhance AI accelerator energy efficiency [C]// Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, 2025: 1118-1132.
[49] Jimenez-Ruiz A, Milano F. Data center model for transient stability analysis of power systems [PP/OL]. [2026-01-21]. https://arxiv.org/abs/2505.16575.
[50] Wang H D, Jing C. ENNP: an enhanced neural networks-based power consumption prediction algorithm to deep learning-based workloads on AI-enabled data centers [J]. Cluster Computing, 2025, 29(1): 36.
[51] Guerreiro J, Ilic A, Roma N, et al. Modeling and decoupling the GPU power consumption for cross-domain DVFS [J]. IEEE Transactions on Parallel and Distributed Systems, 2019, 30(11): 2494-2506.
[52] Ramakrishnan B, Turner C, Alissa H, et al. Understanding the impact of data center liquid cooling on energy and performance of machine learning and artificial intelligence workloads [J]. Journal of Electronic Packaging, 2025, 147 (2): 021003.
[53] Heydari A, Gharaibeh A R, Tradat M, et al. Experimental evaluation of direct-to-chip cold plate liquid cooling for high-heat-density data centers [J]. Applied Thermal Engineering, 2024, 239: 122122.
[54] 中国信息通信研究院.智算中心液冷产业全景研究报告[R/OL]. 2025-08-30. https://www.caict.ac.cn/kxyj/qwfb/ztbg/202508/P020250826611237647336.pdf.
China Academy of Information and Communications Technology. Comprehensive research report on the liquid cooling industry for intelligent computing centers [R/OL]. 2025-08-30. https://www.caict.ac.cn/kxyj/qwfb/ztbg/202508/P020250826611237647336.pdf.
[55] Jiao J J, Li Y, Gong L, et al. Enhanced thermal performance of a hybrid air and liquid cooling system for high power data center servers [J]. Applied Thermal Engineering, 2026, 283: 128878.
[56] Huang Y P, Liu B, Xu S J, et al. Experimental study on the immersion liquid cooling performance of high-power data center servers [J]. Energy, 2024, 297: 131195.
[57] Xu Y Z, Yang Y K, Tian M Y, et al. An investigation into the effects of various IT scheduling algorithms on thermal control and energy efficiency in liquid-cooled data centers [J]. Journal of Building Engineering, 2025, 107: 112798.
[58] Qu S L, Duan K W, Guo Y X, et al. Real-time optimization of the liquid-cooled data center based on cold plates under different ambient temperatures and thermal loads [J]. Applied Energy, 2024, 363: 123101.
[59] Liu Z, Wierman A, Chen Y, et al. Data center demand response: avoiding the coincident peak via workload shifting and local generation [C]// Proceedings of the ACM SIGMETRICS/International Conference on Measurement and Modeling of Computer Systems, 2013: 341-342.
[60] Celestine A N, Sulic M, Wieliczko M, et al. Hydrogen-based energy storage systems for large-scale data center applications [J]. Sustainability, 2021, 13(22): 12654.
[61] Can supercapacitors save the grid from AI's power spikes? [EB/OL]. [2026-01-21]. https://spectrum.ieee.org/supercapacitor-2671883490.
[62] Kurtz J, Ma Z W, Saur G, et al. Analysis of hydrogen infrastructure for the feasibility, economics, and sustainability of a fuel cell powered data center [J]. Sustainable Energy Technologies and Assessments, 2023, 58: 103357.
[63] Wang D, Ren C G, Sivasubramaniam A, et al. Energy storage in datacenters: what, where, and how much? [C]// Proceedings of the 12th ACM SIGMETRICS/PERFORMANCE Joint International Conference on

中国知网 https://www.cnki.net

Measurement and Modeling of Computer Systems, 2012: 187-198.

[64] Zhu Y L, Englmair G, Huang H T, et al. Numerical investigations of a latent thermal energy storage for data center cooling [J]. Applied Thermal Engineering, 2024, 236: 121598.

[65] Bharadwaj S, Das S, Mazumdar K, et al. Predict; don't react for enabling efficient fine-grain DVFS in GPUs [C]// Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, 2023: 253-267.

[66] Zhang Y J, Wang Q, Lin Z, et al. Improving GPU energy efficiency through an application-transparent frequency scaling policy with performance assurance [C]// Proceedings of the Nineteenth European Conference on Computer Systems, 2024: 769-785.

[67] Zhao D, Samsi S, Mcdonald J, et al. Sustainable supercomputing for AI: GPU power capping at HPC scale [C]// Proceedings of the 2023 ACM Symposium on Cloud Computing, 2023: 588-596.

[68] Xue Y Q, Huang J. ReGate: enabling power gating in neural processing units [C]// Proceedings of the 58th IEEE/ACM International Symposium on Microarchitecture, 2025: 1160-1177.

[69] Radovanovic A, Koningstein R, Schneider I, et al. Carbon-aware computing for datacenters [J]. IEEE Transactions on Power Systems, 2023, 38(2): 1270-1280.

[70] Cao Y J, Cheng M, Zhang S F, et al. Data-driven flexibility assessment for Internet data center towards periodic batch workloads[J]. Applied Energy, 2022, 324: 119665.

[71] Ma J H, Yao R Y, Zhang B C, et al. Data-driven flexibility capability modeling of Internet data center considering task dependency [J]. IEEE Internet of Things Journal, 2024, 11 (14): 24538-24550.

[72] Hu Q H, Sun P, Yan S G, et al. Characterization and prediction of deep learning workloads in large-scale GPU datacenters [C]// Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis, 2021: 1-15.

[73] Schrage L. Letter to the editor— a proof of the optimality of the shortest remaining processing time discipline [J]. Operations Research, 1968, 16(3): 687-690.

[74] Liu W Y, Yan Y J, Sun Y M, et al. Online job scheduling scheme for low-carbon data center operation: an information and energy nexus perspective [J]. Applied Energy, 2023, 338: 120918.

[75] Carastan-Santos D, Da Costa G, De Nardin I F, et al. Scheduling with lightweight predictions in power-constrained HPC platforms [J]. IEEE Transactions on Parallel and Distributed Systems, 2025, 36(12): 2609-2620.

[76] Menear K, Wilkinson A, Dykes T, et al. Energy-aware HPC scheduling with LLM-based power prediction [C]// Proceedings of the SC' 25 Workshops of the International Conference for High Performance Computing, Networking, Storage and Analysis, 2025: 1997-2006.

[77] Xu K, Sun D, Tian H, et al. GREEN: carbon-efficient resource scheduling for machine learning cluster [C]// 22nd USENIX Symposium on Networked Systems Design and Implementation, 2025: 999-1014.

[78] Wang Y F, Sun W, Ren P Y, et al. Multi-objective low-carbon scheduling method for data centers based on ensemble reinforcement learning [J]. IEEE Transactions on Smart Grid, 2026, 17(1): 297-308.

[79] Ullman J D. NP-complete scheduling problems [J]. Journal of Computer and System Sciences, 1975, 10(3): 384-393.

[80] Majumdar S, Eager D L, Bunt R B. Scheduling in multiprogrammed parallel systems [J]. ACM Sigmetrics Performance Evaluation Review, 1988, 16(1): 104-113.

[81] Wang Y, Guo Q L, Chen M. Providing load flexibility by reshaping power profiles of large language model workloads [J]. Advances in Applied Energy, 2025, 19: 100232.

[82] Ye Z S, Gao W, Hu Q H, et al. Deep learning workload scheduling in GPU datacenters: a survey [J]. ACM Computing Surveys, 2024, 56(6): 1-38.

[83] Jeon M, Venkataraman S, Phanishayee A, et al. Analysis of large-scale multi-tenant GPU clusters for DNN training workloads [C]// USENIX Annual Technical Conference, 2019: 947-960.

[84] Lu N, Yao R Y, Wang Z Y, et al. Low-carbon and QoS-aware operation of data centers by AI task splitting and allocation [J]. Applied Energy, 2026, 405: 127132.

[85] Wang Y F, Wang X R, Zhang Y W. Leveraging thermal storage to cut the electricity bill for datacenter cooling [C]// Proceedings of the 4th Workshop on Power-Aware Computing and Systems, 2011.

[86] Nadjahi C, Louahlia H, Lemasson S. A review of thermal management and innovative cooling strategies for data center [J]. Sustainable Computing: Informatics and Systems, 2018, 19: 14-28.

[87] Zhao L, Brouwer J, James S, et al. Fuel cell powered data centers: in-rack DC generation [J]. ECS Transactions, 2016, 71(1): 131-139.

[88] Oh H, Jin W C, Peng P, et al. Techno-economic performance of reservoir thermal energy storage for data center cooling system[J]. Applied Energy, 2025, 391: 125858.

[89] Colangelo P, Coskun A K, Megrue J, et al. AI data centres as grid-interactive assets [J]. Nature Energy, 2026, 11 (2): 254-261.

[90] Naug A, Guillen A, Kumar V, et al. LC-Opt: benchmarking reinforcement learning and agentic AI for end-to-end liquid cooling optimization in data centers [PP/OL]. [2026-01-21]. http://arxiv.org/abs/2511.00116.

[91] Liang Y, Yang H B, Wang H L, et al. Enhancing energy efficiency of air conditioning system through optimization of PCM-based cold energy storage tank: a data center case study [J]. Energy, 2024, 286: 129641.

[92] Rahman A, Liu X, Kong F X. A survey on geographic load balancing based data center power management in the smart grid environment[J]. IEEE Communications Surveys & Tutorials, 2014, 16(1): 214-233.

中国知网　https://www.cnki.net

[93] Liu Z H, Lin M H, Wierman A, et al. Greening geographical load balancing[C]// Proceedings of the ACM SIGMETRICS Joint International Conference on Measurement and Modeling of Computer Systems, 2011: 233-244.

[94] James A, Schien D. A low carbon Kubernetes scheduler[C]// International Conference on ICT for Sustainability, 2019.

[95] Sun Y M, Ding Z H, Yan Y J, et al. Privacy-preserving energy sharing among cloud service providers via collaborative job scheduling[J]. IEEE Transactions on Smart Grid, 2025, 16(2): 1168-1180.

[96] Yang T, Jiang H, Hou Y C, et al. Carbon management of multi-datacenter based on spatio-temporal task migration [J]. IEEE Transactions on Cloud Computing, 2023, 11(1): 1078-1090.

[97] Sun J J, Yan Y J, Wang Z Y, et al. Privacy-preserving coordinated operation of cross-enterprise data centers [J]. Applied Energy, 2025, 383: 125343.

[98] Ao R, Luo G, Simchi-Levi D, et al. Optimizing LLM inference: fluid-guided online scheduling with memory constraints[PP/OL]. [2026-01-21]. https://api.semanticscholar.org/CorpusID:277786938.

[99] Shukla D, Sivathanu M, Viswanatha S, et al. Singularity: planet-scale, preemptive and elastic scheduling of AI workloads [PP/OL]. [2026-01-21]. http://arxiv.org/abs/2202.07848.

[100] Choudhury A, Wang Y, Pelkonen T, et al. MAST: global scheduling of ML training across geo-distributed datacenters at hyperscale [C]// 18th USENIX Symposium on Operating Systems Design and Implementation, 2024: 563-580.

[101] You J, Chung J W, Chowdhury M. Zeus: understanding and optimizing GPU energy consumption of DNN training[C]// 20th USENIX Symposium on Networked Systems Design and Implementation, 2023: 119-139.

[102] Yang Z, Meng L, Chung J W, et al. Chasing low-carbon electricity for practical and sustainable DNN training[PP/OL]. [2026-01-21]. http://arxiv.org/abs/2303.02508.

[103] Acun B, Lee B, Kazhamiaka F, et al. Carbon explorer: a holistic framework for designing carbon aware datacenters [C]// Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, 2023: 118-132.

[104] Power-flexible AI factories: a UK-first demonstration of grid-responsive AI infrastructure[EB/OL]. [2026-01-21]. https://www.ngpartners.com/stories/emerald-ai-whitepaper.

[105] 刘祎泽,向月.计及负荷转移需求响应的低碳数据中心光储容量优化配置[J].电力自动化设备,2024,44(7):149-155.
Liu Yize, Xiang Yue. Optimal allocation of photovoltaic and storage capacity in low carbon data center considering load transfer demand response [J]. Electric Power Automation Equipment, 2024, 44(7): 149-155.

[106] Wierman A, Liu Z H, Liu I, et al. Opportunities and challenges for data center demand response[C]// International Green Computing Conference, 2014: 1-10.

[107] 丁巧宜,王梓耀,潘振宁,等.面向电量-调频-容量市场的数据中心园区算力及电力资源规划[J].电力系统自动化,2024,48(1):59-66.
Ding Qiaoyi, Wang Ziyao, Pan Zhenning, et al. Planning of computing power and electric power resources in data center parks for electricity, frequency regulation and capacity markets [J]. Automation of Electric Power Systems, 2024, 48(1): 59-66.

[108] Chen M, Gao C W, Shahidehpour M, et al. Incentive-compatible demand response for spatially coupled Internet data centers in electricity markets[J]. IEEE Transactions on Smart Grid, 2021, 12(4): 3056-3069.

[109] 文淅宇,朱继忠,李盛林,等.基于时空协同的多数据中心虚拟电厂低碳经济调度策略[J].电力系统自动化,2024,48(18):56-65.
Wen Xiyu, Zhu Jizhong, Li Shenglin, et al. Low-carbon economic dispatch for multiple data center virtual power plant based on spatio-temporal collaboration [J]. Automation of Electric Power Systems, 2024, 48(18): 56-65.

[110] Tran N H, Tran D H, Ren S L, et al. How Geo-distributed data centers do demand response: a game-theoretic approach [J]. IEEE Transactions on Smart Grid, 2016, 7(2): 937-947.

[111] Han O Z, Ding T, Mu C G, et al. A two-stage demand response Stackelberg game of data center operators and the system operator based on Kriging metamodel [J]. IEEE Transactions on Automation Science and Engineering, 2024, 21(4): 6666-6679.

[112] 梁晨,曾博,雷乐意,等.算力-电力联合市场下数据中心与配电网集成规划:一种多目标区间-随机优化方法[J].电力系统保护与控制,2025,53(16):120-135.
Liang Chen, Zeng Bo, Lei Yueyi, et al. Integrated planning of data centers and distribution networks under the computing-electricity joint market: a multi-objective interval-stochastic optimization approach [J]. Power System Protection and Control, 2025, 53(16): 120-135.

[113] 曾博,孟自帅,董嘉路,等.考虑电-水耦合灵活性的数据中心与城市配电-水网协同规划研究[J].电工技术学报,2025,40(23):7554-7569.
Zeng Bo, Meng Zishuai, Dong Jialu, et al. Research on synergistic planning of data center and urban electricity-water distribution networks considering electricity-water interdependent flexibility [J]. Transactions of China Electrotechnical Society, 2025, 40(23): 7554-7569.

王　奕(2000—),女,博士研究生,主要研究方向:信息物理系统、联邦学习、数据中心。E-mail: y-wang22@mails.tsinghua.edu.cn

郭庆来(1979—),男,通信作者,教授,博士生导师,主要研究方向:电压稳定与电压控制、信息物理系统、电动汽车。E-mail: guoqinglai@tsinghua.edu.cn

(编辑　杨松迎)

中国知网 https://www.cnki.net

Load Flexibility of Intelligent Computing Centers Aimed for Computing Power-Electric Power Coordination: Challenges and Prospects

WANG Yi, *GUO Qinglai*

(Department of Electrical Engineering, Tsinghua University, Beijing 100084, China)

Abstract: The prevalence of artificial intelligence (AI) has led to a sharp increase in energy consumption and carbon emissions in intelligent computing centers. High volatility on both the resource and load sides makes the exploration of endogenous load flexibility the key to computing power-electric power coordination. First, addressing the unique characteristics of AI computing tasks and hardware infrastructure, this paper analyzes the three major challenges faced by the research on load flexibility of intelligent computing centers: multi-dimensional heterogeneity, fine-grained coupling, and multi-stakeholder collaboration. Then, based on the three core sub-problems of load modeling, flexibility exploitation, and flexibility utilization, this paper reviews the current status of domestic and international research. Finally, the paper prospects future research trends, highlighting the need to advance task-level load modeling adapted to multi-dimensional heterogeneity, conquer dynamic flexibility characterization technologies that perceive fine-grained coupling, and design flexibility expansion application strategies to incentivize multi-stakeholder collaboration.

This work is supported by Smart Grid-National Science and Technology Major Project (No. 2025ZD0804800).

Key words: computing power-electric power coordination; artificial intelligence (AI); intelligent computing center; load flexibility; renewable energy; task scheduling

中国知网　https://www.cnki.net