第50卷 第17期 2026年9月10日
DOI：10.7500/AEPS20260205005
电力系统自动化
Automation of Electric Power Systems
Vol. 50 No. 17 Sept. 10，2026

基于闲时算力调度的算电协同方法与实践

付 智[1,2]，郑博文[1]，刘效辰[1]，程 伟[3]，张 涛[1]，刘晓华[1]
（1. 清华大学建筑技术科学系，北京市 100084；2. 北京共绩科技有限公司，北京市 100080；
3. 中国联通广东省分公司，广东省广州市 510627）

摘要：数据中心能耗持续增长对电力系统构成严峻挑战，尤其是大语言模型推理计算任务的实时响应需求导致了显著的用电尖峰负荷。闲时算力资源规模庞大且具备时空调节灵活性，是实现算电协同的重要潜力资源。为充分发挥闲时算力的柔性调节能力，提出了一种基于闲时算力调度的算电协同方法，以实现计算任务的高稳定性和低成本。首先，分析了图形处理器单机“性能-功耗”非线性特性；其次，构建了面向闲时算力的“时域-地域”调度策略；最后，在真实闲时算力调度平台上开展了工程实践验证。实验结果表明，时域调节使算力系统总功耗降低17%以上，地域调度使计算成本降低近18%，地区绿电利用率提高近20%。所提方法在降低计算能耗、促进可再生能源利用等方面具有显著效果和推广潜力，为新型电力系统和算力网络的协同低碳发展提供了可行方案。

关键词：算电协同；人工智能；数据中心；算力；调度；柔性调节

0 引言

随着人工智能（artificial intelligence，AI）的迅猛发展，算力需求激增，成为未来电力负荷中的重要组成部分。2024年，全球数据中心的电力消耗约为415 TW·h，2019年至2024年的年均增速约为12%，预计2030年电力消耗将增至945 TW·h[1]。截至2024年底，中国数据中心的电力消耗达166 TW·h，2019年至2024年算力总规模的平均增速接近30%[2]。同时，已有研究表明，算力负荷具备灵活调节潜力[3-6]，算电协同对于绿色算力发展和新型电力系统建设具有重要意义。目前，国家持续推动数据中心绿色低碳发展[7]，算电协同已纳入全国一体化算力网和新型电力系统建设的总体框架[8]，青海、河北等省份已开展绿色算力调度平台的试点建设[9]。

AI算力的能源需求主要源于大语言模型（large language model，LLM）计算任务，包括训练任务、微调任务和推理任务。目前，训练任务和微调任务占据了大部分的算力资源和能源消耗。但随着AI全面落地应用，推理任务的算力需求大幅增加，据多家AI科技公司预测，未来推理任务在所有LLM计算任务中的占比将高达90%[10-11]。

从计算特征来看，训练任务、微调任务和少量推理任务为批量型任务，而大量推理任务为交互型任务。对用户提交的交互型推理任务请求数据进行监测分析后发现，受人行为影响，算力需求在时间维度上呈现明显的波峰波谷特征[12]；受用户地理分布影响，算力需求在空间维度上具有分散性。这两个特性构成了推理算力需求与训练算力需求的核心差异。此外，批量型任务允许在规定期限内延迟完成并统一返回结果，而交互型任务对延迟有严格约束，须实时返回计算结果[13]。

在算力任务方面，现有算电协同研究主要针对批量型任务，通过“时间-空间”两维度的算力调度，降低算力系统用电成本并为电力系统提供灵活性。在空间维度上，算力系统跨区域调度具有低成本、高稳定性、低延迟的特点[14]，可响应不同地区的绿电出力或电价变化；在时间维度上，利用批量型任务可延迟完成的特性[15]，将计算任务调度至绿电出力高峰或电价低谷时段完成。文献[16]基于排队等待模型和多目标优化模型，实现了算力任务在地域上迁移、在时域上微调。文献[17]基于模糊电价预测，采用时空联合负载均衡算法优化了运行策略。然而，上述策略均难以适应交互型任务需求，随着交互型

收稿日期：2026-02-05；修回日期：2026-04-29。
上网日期：2026-07-09。
国家工信部算力强基揭榜挂帅项目：“异构算力跨域任务编排系统”；北京市自然科学基金资助项目（QY25032）；中国科协青年人才托举工程资助项目（2023QNRC001）。

中国知网 https://www.cnki.net

任务占比的持续增加，其适用范围将受到显著制约。

针对交互型任务，部分研究也提出了优化调节方法。现有方案主要基于动态电压与频率缩放（dynamic voltage and frequency scaling，DVFS）调整图形处理器（graphics processing unit，GPU）频率，以优化LLM推理服务的能效，同时满足服务水平目标和服务水平协议的要求。文献[18]提出频率缩放技术，实现了截止期限感知的能效调度；文献[19]提出服务水平目标感知框架，能够在满足延迟要求的同时，最小化能源消耗。上述研究虽然在降低瞬时计算功耗方面取得了一定进展，但缺少对算力集群“性能-功耗”特性的实测探索。

已有实验表明，GPU频率与功耗存在非线性关系。文献[20]对不同参数模型和不同任务类型的频率-能耗、频率-推理时间规律进行了实验，论证了推理能效并非由参数规模主导，并发现了LLM推理任务存在频率最优点，可实现单位推理任务的能耗最小化。文献[21]基于计算延迟与计算功耗的非线性关系，对批量型LLM微调任务提出了慢算扩容策略，在保障计算任务在一定时间内完成的前提下，降低了总体功耗。其慢算扩容思路可进一步推广至LLM交互型推理场景，并与地域优化调度耦合实现综合优化。

在算力供给方面，现有研究主要针对专用、独占的算力集群。此类集群计算设备投入成本高，闲置折旧成本可能超过调度带来的电费节约，制约了规模化应用。对于未来大量波动型LLM推理需求，专用算力资源将面临长期低利用率问题，产生高昂的算力成本，难以支撑AI大规模商业化部署。

区别于专用、独占的算力资源，闲时算力是指未在计算进程中或未被满载使用的空闲计算设备所提供的计算资源。当前，大量计算设备的平均利用率偏低，故闲时算力资源广泛存在。闲时算力存在于不同类型场景的计算设备中，如数据中心算力集群、网吧电脑、个人电脑等[18,22]。据统计，目前中国智能算力规模达788 EFLOPS（1 EFLOPS表示每秒执行10^{18}次浮点运算），但平均利用率不足30%，部分地区的集群利用率甚至不足18%[23-25]。约400万台网吧电脑持续一年的实际监测数据表明，平均每台电脑日开机时长不足3 h。Steam游戏平台上有40万中国玩家持有配备RTX 4090 GPU的设备，但日均游戏时长不超过2 h，每日空闲时长占比高达94%[26]。闲时算力分布广、规模大[27]，且无须额外承担设备购置与折旧成本，具备跨地区、跨时段的用能灵活调节潜力。在闲时算力的资源支持下，算电协同的设备成本可以降至极低水平，相比投入成本较高的专用算力集群，更具工程实践价值，在实现算电协同、支撑绿电消纳、促进算力绿色发展方面具有重要意义。

以国外亚马逊弹性计算云（Amazon EC2）为例，其提供的竞价实例（spot instance，SI）作为闲时算力的典型应用形态，被高性能计算、批量作业、科学应用程序等场景调度利用[28]。文献[29-30]基于深度学习构建了SI的估价模型和价格预测以提高使用率。然而，受限于计算设备拥有者使用行为的随机性，算力调度的安全性、稳定性难以保障[30-31]，大规模应用于LLM计算任务并实现算电协同仍面临挑战。

为了解决闲时算力的安全稳定问题，以推进算电协同实践，部分研究针对闲时算力调度进行了尝试和实践。文献[32-33]设计了自适应负载波动调度策略以最大化利用算力资源；文献[34]建立Leftover系统，利用闲时算力资源服务LLM批量型计算任务；文献[35]聚焦于LLM交互型推理任务的迁移安全性问题，融合交替方向乘子法与同态加密技术，以实现隐私保护下的协作优化。以上研究能够提高任务迁移的安全性和稳定性，但在持续保障交互型推理任务服务质量方面仍存在局限，规模化生产级应用面临困难。

综上，虽然当前已有大量关于算力负荷调度与优化的研究，但现有工作多针对批量型计算任务的能耗优化与任务迁移，对于交互型推理任务的研究较少，对于算力集群的性能-功耗特性也缺乏定量实验更新。此外，现有研究多使用专用、独占的算力集群，规模化应用的经济性存在瓶颈，在利用闲时算力进行跨区域、跨时段动态调度方面缺乏系统的理论框架与工程验证。因此，亟须面向算力负荷调节特性，建立兼具工程可行性与推广价值的闲时算力调度方法，并进行面向闲时算力的算电协同优化策略的设计与实践检验。

针对上述问题，本文提出并研发了闲时算力灵活调度平台与调度方法，并开展算电协同实践应用，主要创新点包括：

1）提出了具有高稳定性、低成本的闲时算力调度方法；

2）刻画了GPU和LLM模型对于推理任务的性能-功耗特性；

3）构建了面向闲时算力LLM推理任务的时域-地域调度策略，有效提高了绿电利用率。

1　闲时算力调度框架与平台

闲时算力调度框架的调度对象聚焦于生成式模

中国知网　https://www.cnki.net

型的交互型推理计算任务，旨在纳入分布式集群算力和个人算力，在保障服务稳定的前提下挖掘闲时算力调度潜力，并通过综合调度降低计算总成本、提高绿电利用率。

1.1　闲时算力资源接入与管理

算力调度平台所接入的对象包括数据中心、个人计算设备等社会上广泛存在的各类闲时算力资源。算力调度体系可划分为3个层次：服务端、客户端和闲时算力设备。

图1描述了闲时算力资源接入与管理流程。首先，闲时算力设备会部署专门开发的客户端[36]，在客户端内封装资源监测模块、环境配置模块和任务管理模块。资源监测模块实时检测设备（中央处理器、内存、GPU等）的硬件参数，监控实时负载，推送至部署在云平台的服务端。服务端通过任务调度模块接收并持久化存储最新设备参数与负载信息。环境配置模块检查算力资源是否具备运行任务所需的环境配置（如驱动版本、CUDA版本、库函数、WSL权限等），并进行自动升级与更新以接收并计算任务。实测表明，94%的个人计算设备可全自动完成环境配置。任务管理模块通过进程监控来保证设备自身任务的优先级始终最高，不影响设备持有者的正常使用需求，真正实现闲时资源利用。

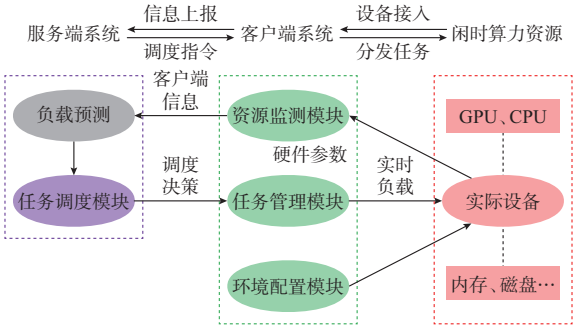


图1　闲时算力资源接入与管理

Fig. 1　Access and management of idle computing power resources

在正式开始承接计算任务前，服务端系统须判断目标设备能否持续空闲一定时间，以规避频繁迁移带来的时间开销。根据设备i的历史负载记录，对t时刻后的持续空闲时间$T_{i,t}$进行概率预测，其累积分布函数$F_{T_{i,t}}(x)$定义为：

$$F_{T_{i,t}}(x)=P(T_{i,t}\leqslant x)\quad x\geqslant 0 \tag{1}$$

式中：x为持续空闲时间取值；$P(\cdot)$为概率函数。

在设备i的历史负载记录中，提取第h天t时刻开始的连续空闲时段信息，累计K_i天。采用经验分布函数$\hat{F}_{T_{i,t}}(x)$估计式(1)：

$$\hat{F}_{T_{i,t}}(x)=\frac{1}{K_i}\sum_{h=1}^{K_i}1\{T_{i,t,h}\leqslant x\} \tag{2}$$

式中：$1\{\cdot\}$为指示函数，当括号内条件成立时取1，否则取0；$T_{i,t,h}$为设备i第h天t时刻后的连续空闲时间。

设定容忍接入失效率为0.05，最小持续时间阈值为0.5 h，将式(2)代入式(3)，以确定接入判据。

$$\hat{T}_{i,t}=\inf\{x\in\mathbf{R}:\hat{F}_{T_{i,t}}(x)\geqslant 0.05\} \tag{3}$$

式中：$\hat{T}_{i,t}$为设备i在容忍接入失效率下的最小持续空闲时间阈值估计。若$\hat{T}_{i,t}$小于0.5 h，则t时刻不接入设备i。

根据设备性能将不同设备进行分类，提前分发不同复杂度的模型镜像至本地以待调用。服务端周期性执行调度算法，筛选可用设备、生成调度决策，并将任务指令下达至客户端的任务管理模块。客户端调用本地镜像执行计算，完成后将结果回传至服务端。在整个过程中，平台通过对计算设备历史使用模式的学习实现忙闲状态预测，进而实现任务的精准分发；通过硬件筛选、软件环境自动配置及镜像预置，确保平台具备随时承接任务的能力。此外，通过进程隔离和磁盘加密来保障本地数据和计算任务数据的安全。在实际生产中，为保障高质量服务，还须在网络层完成内网穿透和链路打通等工作，由于非本文研究重点，不再赘述。目前，该客户端可自行下载进行测试。

据此，实现了对闲时算力资源的接入和管理，保障了接入的安全性与稳定性，为后续利用闲时算力开展算电协同奠定了基础。

1.2　算力任务迁移

在闲时算力调度平台中，算力资源的稳定使用要求算力任务迁移具备足够的速度和连续性。一方面，闲时算力资源可能因资源提供者自身使用需求随时下线，为保障在线服务不中断，须快速将计算任务迁移至其他可用资源；另一方面，新型电力系统背景下不同地区的电价存在差异，要求调度平台具备快速响应电价变化并灵活调控的能力。

如图2所示，算力迁移体系划分为用户侧、服务端和安装客户端的算力设备。用户侧提供计算任务请求，传递至服务端的任务调度模块。任务调度模块根据目标任务调度方案中各数据中心的任务副本数量，通过负载均衡实现任务的迁移。

在推理计算场景下，由于模型镜像已在设备筛选过程中提前下载部署，任务迁移仅涉及指令与少量过程数据的传输，能够保证迁移速度，基本不产生迁移开销，并保障在线服务在迁移过程中不中断。

中国知网　https://www.cnki.net

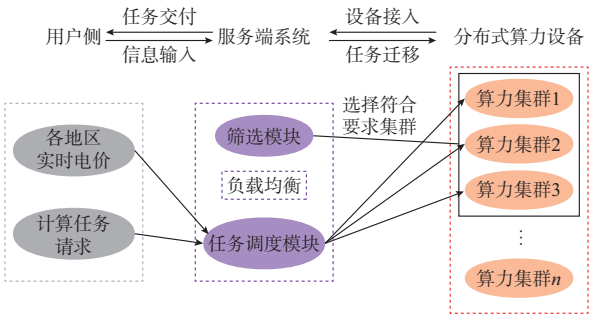


图2　算力任务迁移示意图
Fig. 2　Schematic diagram of computing power task transfer

这一特性适应了推理任务的分散性，可利用闲时算力为不同地区的推理请求提供稳定服务。

1.3　闲时算力调度平台

基于以上接入、管理与迁移的基础，本文开发了闲时算力调度平台[37]，已实现空间尺度上的调度迁移和时间尺度上的弹性扩缩容。平台涵盖青海、河南、福建、重庆等多个地区的算力集群资源，支持便捷部署生产级推理服务。计算设备掉线时，可快速切换到其余空闲设备，保障服务稳定性，服务水平协议（service level agreement，SLA）达到99.9%。该平台为闲时算力算电协同调度提供了技术支撑和实践基础，本文3.2节的实验亦依托该平台开展。

2　基于闲时算力的算电协同调度策略

算力调度策略从时域和地域两个维度展开。在时域上，采用慢算扩容策略，通过降低单机计算速度来降低功耗，同时扩增节点以保障服务质量；在地域上，采用地区间迁移策略，将算力调度至电价更低的地区，从而降低成本并提升绿电利用率[38]。

2.1　时域策略

2.1.1　单机的性能-功耗特性

已有研究表明，GPU单机的功耗与性能之间存在凸性关系[18-20]。GPU单机功耗满足：

$$\begin{cases} P^{\mathrm{dyn}} \propto CV^2 f \\ P^{\mathrm{sta}} \propto V \\ P = P^{\mathrm{dyn}} + P^{\mathrm{sta}} \end{cases} \tag{4}$$

式中：P^{dyn}为动态功耗；C为动态电容；V为电压；f为时钟频率；P^{sta}为静态功耗；P为总功耗。

对于GPU配置为s的设备，功耗P_s与时钟频率f的关系[20]为：

$$P_s(f) = \alpha_s^{\mathrm{P}} f^3 + \beta_s^{\mathrm{P}} f + \gamma_s^{\mathrm{P}} \tag{5}$$

式中：α_s^{P}、β_s^{P}、γ_s^{P}为GPU配置为s的设备功耗-频率多项式拟合参数。

由于GPU单机性能与时钟频率f接近正比关系，单机性能与功耗呈非线性，故性能-功耗曲线表现为上凸特性。

针对LLM推理型计算任务，其性能可通过瞬时吞吐量表征。本文分别使用2种GPU卡（设为A卡和B卡）、3类LLM和简单/复杂两种交互型命令开展性能-功耗特性实验，具体实验信息见附录A表A1。实验结果如图3(a)所示。图中：散点表示实测数据；实线表示三次多项式拟合结果；模型名带“*”表示复杂交互型命令。实验结果表明，当性能降低10%时，A卡4组实验的功耗均下降超过23%，B卡2组实验的功耗均下降超过16%。

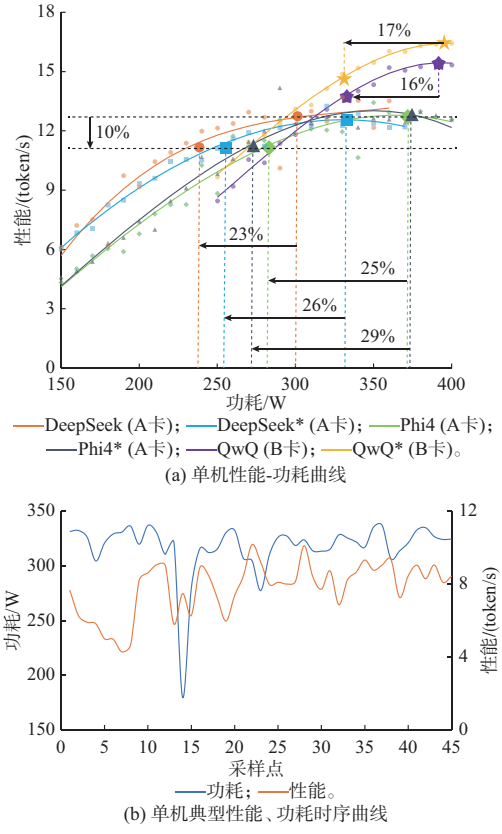


图3　单机实验结果
Fig. 3　Single-machine experiment results

由实验可拟合出单机性能与功耗的关系如下：

$$g_s(P) = \alpha_s^{\mathrm{W}} P^3 + \beta_s^{\mathrm{W}} P^2 + \gamma_s^{\mathrm{W}} P + \eta_s^{\mathrm{W}} \tag{6}$$

式中：$g_s(P)$为单机性能关于功耗的拟合函数；α_s^{W}、β_s^{W}、γ_s^{W}、η_s^{W}为GPU配置为s的设备性能-功耗多项式拟合参数。

图3(b)展示了单机性能与功耗在运行过程中存在一定范围的波动，该不稳定性对实际调度实践的影响将在第3章具体分析。

2.1.2　慢算扩容调节策略

基于2.1.1节所述单机性能-功耗特性，在时间

中国知网　https://www.cnki.net

尺度上通过慢算扩容策略挖掘GPU的用能灵活性潜力。文献[21]针对LLM微调任务进行建模，考虑多GPU之间的传输时延和梯度聚合时延，以及频率调节后对计算时间和功耗的影响，对单个微调任务的总能耗寻找最优频率和GPU数。式(7)拟合了微调计算任务的时延与频率和GPU数的关系，结合式(5)得到总能耗的表示式，如式(8)所示。

$$T_s(n,f)=\alpha_s^{\mathrm{T}}+\beta_s^{\mathrm{T}}f^{-1}+\gamma_s^{\mathrm{T}}n \tag{7}$$

$$E_s(n,f)=nP_s(f)T_s(n,f) \tag{8}$$

式中：$T_s(n,f)$为单个微调任务时延；n为GPU数；α_s^{T}、β_s^{T}、γ_s^{T}为GPU配置为s的设备时延-频率多项式拟合参数；$E_s(n,f)$为单个微调任务总能耗。

对于LLM推理交互型任务，慢算扩容策略可保障瞬时吞吐量而非任务完成时间。此外，推理场景下各GPU独立承载用户请求，不涉及模型并行中的梯度同步与跨卡通信，总吞吐量可近似为各GPU吞吐量的线性叠加。因此，将慢算扩容策略简化为：

$$\begin{cases}\min\limits_{w,\,n} P_s^{\mathrm{tot}}=nP_s\\ \text{s.t.}\quad P_s=g_s^{-1}(w)\\ \qquad nw=n_0w_0\quad w\in(0,w_0],n\in\mathbf{N}_+,n\geqslant n_0\end{cases} \tag{9}$$

式中：P_s^{tot}为总瞬时功耗；P_s为单机瞬时功耗；$g_s^{-1}(\cdot)$为性能-功耗拟合函数的逆函数；w为单机瞬时吞吐量；n_0为原始GPU数；w_0为原始单机瞬时吞吐量。

通过降低单机运行功率并扩容计算节点补偿能耗性能损失，可在维持总服务性能不变的前提下降低系统总功耗。当算力集群同时运行多种类型的计算任务时，还须决策将富余闲时GPU资源分配给节能潜力更大的任务进行扩容。针对每一算力集群，在式(9)的基础上求解以下优化问题：

$$\begin{cases}\min\limits_{\Delta\boldsymbol{n}_t} J_t=\underbrace{\theta_t\sum\limits_{j\in\mathcal{B}}P_{j(s)}(n_{j,t}+\Delta n_{j,t})}_{\text{电费}}+\underbrace{y\sum\limits_{j\in\mathcal{B}}(n_{j,t}+\Delta n_{j,t})}_{\text{租赁费}}\\ \text{s.t.}\quad P_{j(s)}=g_{j(s)}^{-1}(w_j)\quad\forall j\in\mathcal{B}\\ \qquad n_{j,t}w_{j,0}=(n_{j,t}+\Delta n_{j,t})w_j\\ \qquad\sum\limits_{j\in\mathcal{B}}(n_{j,t}+\Delta n_{j,t})\leqslant N_t^{\mathrm{GPU}}\\ \qquad w_j\in(0,w_{j,0}],\Delta n_{j,t}\in\mathbf{N},\forall j\in\mathcal{B}\end{cases} \tag{10}$$

式中：$\Delta n_{j,t}$为t时刻任务j扩容增加的GPU数；$\Delta\boldsymbol{n}_t=[\Delta n_{1,t},\Delta n_{2,t},\cdots,\Delta n_{|\mathcal{B}|,t}]^{\mathrm{T}}$为$t$时刻各任务扩容GPU数决策向量；$n_{j,t}$为$t$时刻任务$j$使用的GPU数；$J_t$为$t$时刻瞬时运行成本；$\mathcal{B}$为任务集合；$\theta_t$为$t$时刻算价(综合机柜租赁、供应商利润与电价后的算力使用价格，参考市场行情，取电价的4倍)[39]；$j(s)$为任务j对应的设备GPU配置；$P_{j(s)}$为任务j的单机瞬时功耗；y为每台闲时设备的租赁成本；w_j为任务j的瞬时吞吐量；$w_{j,0}$为任务j在优化前的初始瞬时吞吐量；N_t^{GPU}为t时刻可用GPU总资源。

式(10)为混合整数非线性规划问题。本文对$g_{j(s)}^{-1}(\cdot)$进行分段线性化，对双线性项约束$n_{j,t}w_{j,0}=(n_{j,t}+\Delta n_{j,t})w_j$进行McCormick包络松弛，将式(10)转化为混合整数线性规划问题，借助Gurobi求解。

2.2　地域策略

2.2.1　闲时算力资源网络

在闲时算力系统中，算力资源广泛分布于不同地区、不同类型的终端设备中，可能来自企业数据中心、校园机房、个人电脑、边缘设备等，构成多层次、异构化的算力网络。

由于地域差异，不同地区的电力负荷、电价水平以及绿电占比存在明显差异。闲时算力调度平台可基于上述差异动态调度算力，在电价较低或绿电占比更高的地区优先分发计算任务，从而实现能源成本的最小化与绿色能源利用的最大化。

闲时算力资源网络中可用总量通常远超系统实际需求，在资源利用上仍具有较大的优化空间。然而，由于闲时算力具有上下线不确定性，集群资源可能出现较大波动，且任务调度本身存在时延与一定概率的传递丢包，优化调度时须避免频繁迁移的发生。

2.2.2　地区间调度策略

闲时算力调度平台可通过地区间调度将算力迁移至电价最低的地区，以降低计算成本、提高绿电利用率[40]。考虑$|\mathcal{R}|$个参与调度的地区，t时刻的静态单步调度问题可表示为：

$$\begin{cases}\min\limits_{\boldsymbol{M}_t} J_t=\sum\limits_{r\in\mathcal{R}}(\theta_{r,t}\bar{P}_{r,t}+y_r)(D_{r,t}+M_{r,t})\\ \text{s.t.}\quad -D_{r,t}\leqslant M_{r,t}\leqslant S_{r,t}-D_{r,t}\\ \qquad\sum\limits_{r\in\mathcal{R}}(D_{r,t}+M_{r,t})=N_t^{\mathrm{Tot}}\\ \qquad\theta_{r,t}=4c_{r,t}\\ \qquad D_{r,t},M_{r,t}\in\mathbf{Z},\forall r\in\mathcal{R}\end{cases} \tag{11}$$

式中：$M_{r,t}$为t时刻地区r的任务副本净迁移量决策变量($M_{r,t}>0$表示净迁入，$M_{r,t}<0$表示净迁出)；$\boldsymbol{M}_t=[M_{1,t},M_{2,t},\cdots,M_{|\mathcal{R}|,t}]^{\mathrm{T}}$为各地区任务副本数迁移决策向量；$\mathcal{R}$为地区集合；$\theta_{r,t}$为$t$时刻地区$r$算价；$\bar{P}_{r,t}$为$t$时刻地区$r$单台GPU的平均运行功耗；$y_r$为地区$r$单台设备的租赁成本；$D_{r,t}$为$t$时刻调度前地区$r$上已有的任务副本数；$S_{r,t}$为$t$时刻地区$r$可接入

中国知网　https://www.cnki.net

任务副本上限；N_t^{Tot}为t时刻用户任务的总副本需求量；$c_{r,t}$为t时刻地区r电价。

在实际运行中，闲时算力资源存在上下线不确定性，集群规模可能出现较大波动。为抑制频繁迁移、兼顾未来电价与资源变化，在式(11)基础上引入基于历史数据的滚动预测优化，表示如下：

$$\begin{aligned}\min_{\{M_{r,\tau}\}} J_t' = &\sum_{r\in\mathcal{R}}(\theta_{r,t}\bar{P}_{r,t}+y_r)(D_{r,t}+M_{r,t})+\\&\sum_{\tau=t+1}^{t+H}\sum_{r\in\mathcal{R}}(\hat{\theta}_{r,\tau}\hat{\bar{P}}_{r,\tau}+y_r)(D_{r,\tau}+M_{r,\tau})+\\&\sum_{\tau=t}^{t+H}\sum_{r\in\mathcal{R}}(\mu_{\mathrm{in}}M_{r,\tau,\mathrm{in}}+\mu_{\mathrm{out}}M_{r,\tau,\mathrm{out}})\end{aligned}\tag{12}$$

式中：τ为滚动窗口内时刻索引；J_t'为滚动窗口内各时刻期望成本和迁移惩罚项之和；H为滚动窗口长度；$\hat{\theta}_{r,\tau}$为τ时刻地区r的算价预测值；$\hat{\bar{P}}_{r,\tau}$为τ时刻地区r单台GPU的平均运行功耗预测值；$M_{r,\tau,\mathrm{in}}$为τ时刻地区r的非负迁入分量决策变量；$M_{r,\tau,\mathrm{out}}$为τ时刻地区r的非负迁出分量决策变量；μ_{in}为迁入惩罚系数；μ_{out}为迁出惩罚系数。

式(12)的完整约束条件见附录B式(B2)—式(B8)及说明。采用Gurobi求解该动态规划问题后，取t时刻的迁入/迁出决策作为最优方案，如图4所示，为低电价地区标记高优先级，优先通过信息序列进行任务分配。

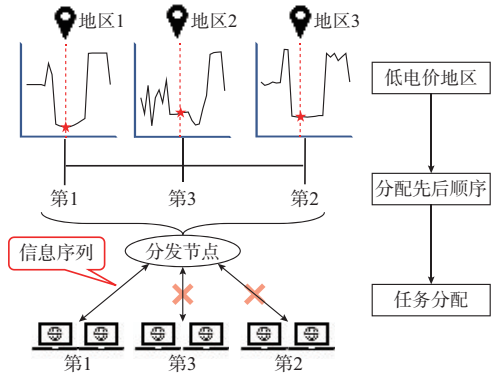


图4　算力地域调度策略

Fig. 4　Regional scheduling strategy for computing power

2.3　时域-地域耦合策略

将2.1节和2.2节所述策略耦合，即得到时域-地域耦合优化策略。完整问题表述和约束条件见附录C式(C1)—式(C12)及说明。优化问题耦合了式(10)与式(11)的约束结构，同样采用分段线性化与McCormick包络松弛，借助Gurobi求解器求解。求得的全局最优解可同时兼顾时域降速扩容与地域迁移、成本最低与服务质量。

3　实践与分析

在2.1.1节所述实验过程中，图3(b)表明单机性能与功耗均存在一定波动。对于慢算扩容策略，实际动态变化的性能能否绝大部分时间满足原始性能要求，有待实验验证；对于地域调度策略，单机功耗的不稳定性在规模化场景下是否会产生较大的聚合波动，从而影响调度决策，亦须通过规模化实验观察。

3.1　时域调节实践

3.1.1　时域调节实验设置

针对2.1.2节所述慢算扩容策略，组建由8张RTX 4090 GPU组成的算力节点，2个节点构成1个算力集群进行实验。电价取0.6元/(kW·h)[41]，则算价为2.4元/(kW·h)。由于采用闲时算力，设备租赁成本理论上为0，但实际运行中为保障基本服务，部分采用“半闲时算力”(即在特定时段将闲时算力视作专用算力)，故取租赁成本为0.5元/(卡·h)。将DeepSeek-r1-14B和QwQ-32B模型作为两个任务，初始状态下两个任务各满载部署5张GPU。

3.1.2　时域调节结果分析

对于上述两个任务，优化算法均扩容1张GPU，相应降低每张GPU的运行功耗。优化前后瞬时吞吐量对比如图5(a)所示。可见，优化后性能与原始性能基本一致，能够保障平均服务质量不降低，动态服务质量基本不降低。如图5(b)所示，QwQ模型总功耗降低17.27%，DeepSeek模型总功耗降低25.70%，且优化后性能均略高于初始性能。

3.2　地域调度实践

3.2.1　地域调度实验设置

针对2.2.2节所述地区间调度策略，依托本文开发的闲时算力调度平台[37]，开展多GPU跨地区算力调度实验。实验采用重庆算力集群15张RTX 4090 GPU、福建算力集群10张RTX 4090 GPU和河南算力集群15张RTX 4090 GPU，同时部署20个LLM交互型任务。

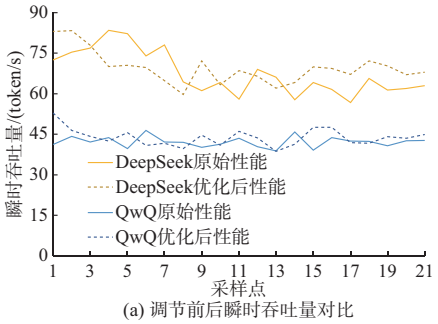
根据上述3个地区典型日风光发电量模拟生成对应电价，以1 h为调整周期更新地区优先级并调度任务。对于GPU突然离线的情形，将溢出任务调度至有闲时算力资源的地区。

3.2.2　地域调度结果分析

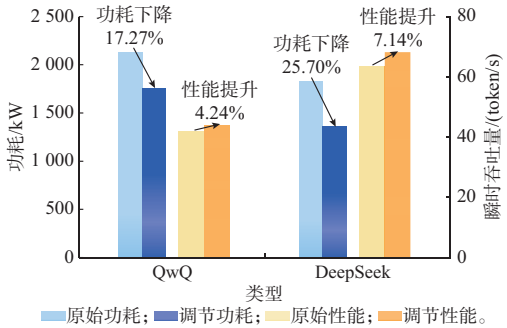
1)规模化运行分析

如图6(a)所示，当某地区部分GPU离线时，平台能够有效保障计算任务的连续性与稳定性，在较短响应时间内将任务重新部署至其他地区。同时，若出现集群短时间设备频繁上下线情形而引发频繁调度过程，将产生不可接受的累积时延，进一步验证了2.2.2节中引入频繁调度抑制因子的必要性。

中国知网　https://www.cnki.net



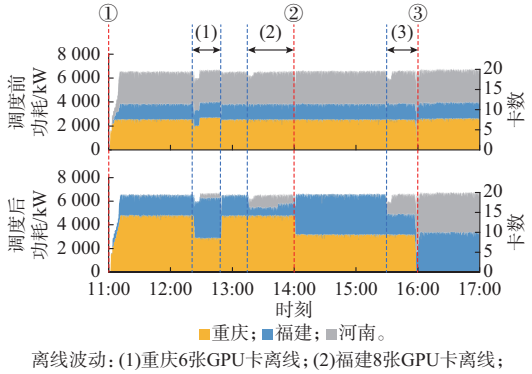
(a) 调节前后瞬时吞吐量对比



(b) 调节前后功耗、性能变化对比

图5　慢算扩容实验结果

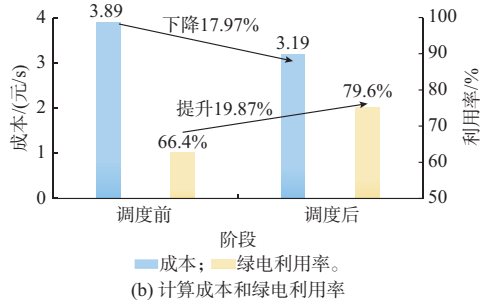
Fig. 5　Experiment results of slow-computation and scaling-up



离线波动：(1)重庆6张GPU卡离线；(2)福建8张GPU卡离线；(3)重庆、福建各5张GPU卡离线。

电价变化：①最低电价：重庆；中等电价：福建；最高电价：河南；②最低电价：福建；中等电价：重庆；最高电价：河南；③最低电价：河南；中等电价：福建；最高电价：重庆。

(a) GPU离线事件和电价变化



(b) 计算成本和绿电利用率

图6　算力地域调度实验结果

Fig. 6　Regional scheduling experiment results of computing power

图6(a)所示瞬时功耗曲线表明，单机功耗的波动性在多GPU聚合场景下不会产生显著的一致性波动，调度决策在规模化实践中未引发稳定性或安全性问题。2.1.1节中观测到的单机功耗波动源于LLM交互型推理过程中解码阶段的时变性与随机性——解码过程对每个输出token进行概率分布的随机采样[42]，使推理过程具有固有的不确定性。同时，不同模型、不同输入/输出长度等均影响推理过程[43]，使得各GPU功耗波动的同步性极低，规模化场景下的聚合波动因而得到自然平抑。

2)优化结果分析

图6(a)记录了实验过程中分别出现的数次GPU离线事件和电价变化，地区设备离线与电价优先级变更均触发了算力地域调度。详细分析见附录D。

实验结果表明，地域调度可有效降低计算成本并提升绿电利用率。如图6(b)所示，地域调度使算力系统计算成本降低了17.97%，绿电利用率提升了19.87%。

3.3　时域-地域耦合实践

3.3.1　案例介绍

在3.2节实践基础上，应用2.3节的时域-地域耦合优化模型，考虑重庆、福建、河南3个地区规模化RTX 4090 GPU算力集群开展仿真分析。各地区可调度算力资源上限为600张RTX 4090 GPU，可用算力卡数可能产生波动。电价采用与3.2节相同的模拟数据，推理任务需求取自某企业真实请求数据，详细数据分析见附录E图E1。以5 min为最小时间区间进行典型日的实时地区调度与慢算扩容调节。各地区资源短时间波动参考算了么平台[36]数据进行模拟，并对大规模上下线(波动超过20%设备数)事件进行仿真。

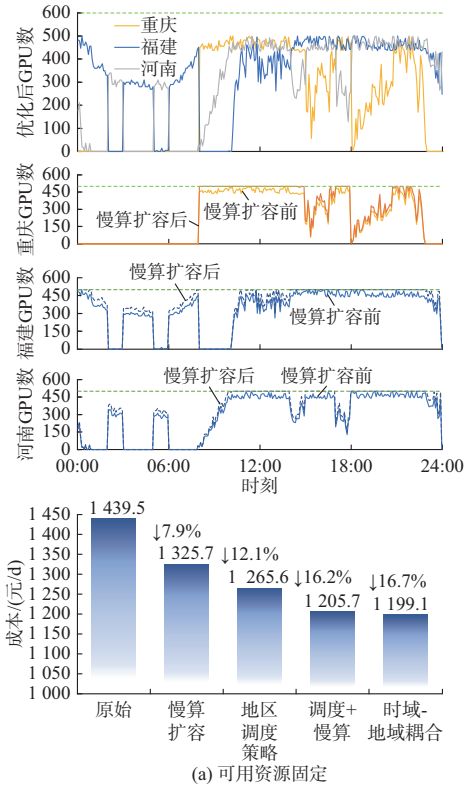
3.3.2　结果分析

对于可用资源固定为500张GPU卡的情形和可用资源波动变化的情形，时域-地域耦合优化将任务优先迁至电价更低地区的算力集群进行计算，实现了对电价的实时响应，如图7所示。同时，图7展示了慢算扩容调节效果，在不同时刻各地区算力集群均实现了不同程度的降速扩容。图中：绿色虚线表示各地区可用算力资源上限。

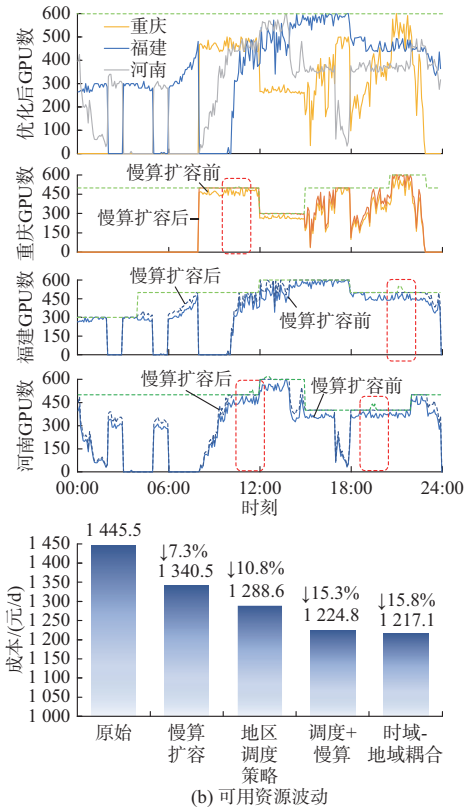
图7(b)体现了调度算法对较大资源波动的及时响应。图中：红色虚线框标记了短时段的高频资源波动情形，调度算法在该场景下保持了良好的稳定性，有效避免了计算任务的频繁跨地区迁移。

由图7可见，时域-地域耦合优化在可用资源固定与波动情形下的成本分别降低了16.7%和

中国知网　https://www.cnki.net



(a) 可用资源固定



(b) 可用资源波动

图7　时域-地域耦合优化实验结果

Fig. 7　Experimental results of temporal-regional coupling optimization

15.8%，均展现出显著的灵活性潜力。进一步拆解地区调度与慢算扩容各自的贡献后，对比联合优化与先地区调度再慢算扩容的串行策略效果。结果表明，联合优化的成本降低幅度均优于上述串行策略，证实了联合优化能够搜索到成本最低的全局最优解。

3.4　讨论与展望

实验结果充分验证了基于闲时算力的算电协同在节能降耗与促进绿电利用方面的有效性。通过时域调节与地域调度的协同实施，在保持服务性能稳定的前提下实现了算力资源与电力资源的协同优化。

在时域调节方面，慢算扩容策略功耗降低超17%，为算力集群的动态能耗管理提供了可行的调节路径。在地域调度方面，调度平台在多区域、多电价、多任务环境下展现了实时响应与自适应调度能力。当部分地区出现节点下线或电价波动时，系统能够迅速重新分配任务并实现不中断迁移，保障算力服务的连续性和可靠性。基于电价信号的优先级调整机制实现了算力与电价的动态匹配，使整体计算成本降低近18%，区域间绿电利用率提升近20%。

同时，本实验所利用的均为闲时算力资源而非专用资源，除调度系统的部署运营费用之外无额外设备投入，所节约的成本远高于资源投入成本，算电协同的经济可行性得到了验证。

本文所提基于闲时算力的时域-地域联合调度策略在地区级多算力集群中的实践结果，初步展现了其在大规模算力-电力网络中的应用潜力。但本文目前仅基于大型智算集群开展实验，尚缺少基于其他类型闲时算力资源的验证。此外，根据密度定律[44]，未来更加分散的个人算力节点将占据越来越大的比例。分散算力将成为日常用电的重要组成部分，海量细粒度算力资源对优化调度策略提出了更高要求，未来分布式算力与分布式能源的关联关系与协同发展路径有待深入研究。

后续研究工作须针对不同类型算力资源开展更全面的实验，并在以下方向深化：

1）柔性潜力评估。在“全域-局域-个体”多层级估计算力资源的柔性调节潜力，完善各层级与电网的互动模式，指导多层级异构灵活算力体系的构建。

2）多种类算力资源预测。针对不同类型、不同区域的闲时算力资源进行总量估计与动态预测，支撑更精细化的调度决策。

3）个人分布式算力资源特征研究。探究个人分布式算力资源的利用模式，探索分布式算力与分布式能源的关联关系与协同发展路径。

综上，本文的实践验证了基于闲时算力发展算

中国知网　https://www.cnki.net

电协同的可行性与前景。随着算力需求的持续增长,基于闲时算力资源的算电协同有望成为新型电力系统需求侧柔性潜力挖掘的重要发展方向。

4　结语

本文构建了可靠的闲时算力调度平台,设计了基于闲时算力调度的算电协同方法与策略,并通过实践验证了所提方法在交互型推理任务下降低计算能耗、提升绿电利用率的效果。通过慢算扩容调节和跨区域调度,本文方法能够降低运行成本近18%,提升绿电利用率近20%,且完全基于闲时算力资源,无额外设备占用成本,为构建高效、低碳、可持续的算力资源网络提供了可行方案。

随着AI技术的持续发展,算力系统与电力系统之间的耦合将日益紧密。基于闲时算力调度的算电协同有望成为二者交互的理想形式,充分挖掘算力系统作为全新需求侧柔性资源的潜力,发挥"以算代储"的作用,为能源高效利用和算力绿色转型作出重要贡献。

本文中部分相关数据由青海省数据局提供,单机"性能-功耗"特性部分实验在青海省数据局支持下完成,在此对青海省数据局表示衷心感谢!

附录见本刊网络版,点击 http://www.aeps-info.com/aeps/article/abstract/20260205005,或扫描英文摘要后二维码,可阅读全文。

参 考 文 献

[1] International Energy Agency (IEA). Energy and AI[R]. Paris: International Energy Agency, 2025.

[2] 中国信息通信研究院产业与规划所,内蒙古和林格尔新区管委会.绿色算力发展研究报告(2025年)[R].北京:中国信息通信研究院,2025.
China Academy of Information and Communications Technology, Institute of Industry and Planning, and Administrative Committee of Horinger New Area, Inner Mongolia. Green computing power development research report (2025) [R]. Beijing: China Academy of Information and Communications Technology, 2025.

[3] Chen S R, Li P, Ji H R, et al. Operational flexibility of active distribution networks with the potential from data centers [J]. Applied Energy, 2021, 293: 116935.

[4] Alaperä I, Honkapuro S, Paananen J. Data centers as a source of dynamic flexibility in smart girds[J]. Applied Energy, 2018, 229: 69-79.

[5] 王永真,唐豪,魏一鸣,等.中国数据中心综合能耗及其灵活性预测[J].北京理工大学学报(社会科学版),2025,27(2):12-18.
Wang Yongzhen, Tang Hao, Wei Yiming, et al. Comprehensive energy consumption and flexibility forecast of data centers in China [J]. Journal of Beijing Institute of Technology (Social Sciences Edition), 2025, 27(2): 12-18.

[6] 丁巧宜,王梓耀,潘振宁,等.面向电量-调频-容量市场的数据中心园区算力及电力资源规划[J].电力系统自动化,2024,48(1):59-66.
Ding Qiaoyi, Wang Ziyao, Pan Zhenning, et al. Planning of computing power and electric power resources in data center parks for electricity, frequency regulation and capacity markets [J]. Automation of Electric Power Systems, 2024, 48(1): 59-66.

[7] 数据中心绿色低碳发展专项行动计划[EB/OL].[2025-07-03]. https://www.gov.cn/zhengce/zhengceku/202407/content_6964165.htm.
Special action plan for green and low-carbon development of data centers[EB/OL]. [2025-07-03]. https://www.gov.cn/zhengce/zhengceku/202407/content_6964165.htm.

[8] 陈敏,郭庆来,井汤博,等.算电协同探索:HVDC侧储备一体电池灵活性挖掘[J].电力建设,2025,46(2):1-12.
Chen Min, Guo Qinglai, Jing Tangbo, et al. Exploring synergy of computing power and electricity: unearthing flexibility of high-voltage direct current-side integrated backup and energy storage batteries[J]. Electric Power Construction, 2025, 46(2): 1-12.

[9] 绿色算力产业发展工作成效显著[EB/OL].[2025-01-19]. https://app.people.cn/h5/detail/normal/6152684713772032.
Remarkable achievements in the development of the green computing power industry[EB/OL]. [2025-01-19]. https://app.people.cn/h5/detail/normal/6152684713772032.

[10] Morgan P. The battle begins for AI inference compute in the datacenter [EB/OL]. [2025-09-10]. https://www.nextplatform.com/2024/09/10/the-battle-begins-for-ai-inference-compute-in-the-datacenter/#:~:text=applications%20or%20to%20create%20entirely,processes%20with%20modest%20packaging%20needs.

[11] Desislavov R, Martínez-Plumed F, Hernández-Orallo J. Trends in AI inference energy consumption: beyond the performance-vs-parameter laws of deep learning[J]. Sustainable Computing: Informatics and Systems, 2023, 38: 100857.

[12] 胡明,李晓华,蔡泽祥,等.基于计算负荷预测的配用电终端算力供需动态均衡方法[J].电力自动化设备,2024,44(12):52-60.
Hu Ming, Li Xiaohua, Cai Zexiang, et al. Dynamic balancing method for supply and demand of power distribution and consumption terminal arithmetic based on computational load forecasting[J]. Electric Power Automation Equipment, 2024, 44(12): 52-60.

[13] 秦雪雪,李泽宁,薛屹洵,等.计及建筑热动态特性的数据中心时空协调两阶段鲁棒优化方法[J].电力系统自动化,2025,49(11):59-69.
Qin Xuexue, Li Zening, Xue Yixun, et al. Two-stage robust optimization method for spatio-temporal coordination of data center considering thermal dynamic characteristics of buildings [J]. Automation of Electric Power Systems, 2025, 49(11): 59-69.

[14] Cao Y J, Cao F, Wang Y J, et al. Managing data center

中国知网 https://www.cnki.net

cluster as non-wire alternative: a case in balancing market[J]. Applied Energy, 2024, 360: 122769.
[15] Yu L, Jiang T, Zou Y L. Distributed real-time energy management in data center microgrids[J]. IEEE Transactions on Smart Grid, 2018, 9(4): 3748-3762.
[16] Zhang L T, Deng J K, Li Q F, et al. Research on data center computing resources and energy load co-optimization considering spatial-temporal allocation [J]. Computers and Electrical Engineering, 2024, 116: 109206.
[17] Luo J Y, Rao L, Liu X. Spatio-temporal load balancing for energy cost optimization in distributed Internet data centers[J]. IEEE Transactions on Cloud Computing, 2015, 3 (3): 387-397.
[18] Ilager S, Muralidhar R, Rammohanrao K, et al. A data-driven frequency scaling approach for deadline-aware energy efficient scheduling on graphics processing units (GPUs)[C]// 20th IEEE/ACM International Symposium on Cluster, Cloud and Internet Computing, 2020.
[19] Kakolyris A K, Masouros D, Xydis S, et al. SLO-aware GPU DVFS for energy-efficient LLM inference serving[J]. IEEE Computer Architecture Letters, 2024, 23(2): 150-153.
[20] Maliakel P J, Ilager S, Brandic I. Characterizing LLM inference energy-performance tradeoffs across workloads and GPU scaling[PP/OL]. [2025-08-05]. https://arxiv.org/abs/2501.08219.
[21] Wang Y, Guo Q L, Chen M. Providing load flexibility by reshaping power profiles of large language model workloads[J]. Advances in Applied Energy, 2025, 19: 100232.
[22] Sun J J, Fu Z, Ma J H, et al. Sharing computing power: enhancing energy efficiency and reducing carbon emissions[J]. IEEE Energy Sustainability Magazine, 2026, 2(1): 103-119.
[23] 中国信息通信研究院.云计算蓝皮书(2025年)[R].北京:中国信息通信研究院,2025.
China Academy of Information and Communications Technology. Cloud computing blue book (2025)[R]. Beijing: China Academy of Information and Communications Technology, 2025.
[24] 都芃.利用率仅三成,"沉睡"的算力如何激活[EB/OL].[2025-07-17].https://gdstc.gd.gov.cn/kjzx_n/mtjj/content/post_4745744.html.
Du Peng. With a utilization rate of only 30%, how can we awaken "dormant" computing power[EB/OL]. [2025-07-17]. https://gdstc. gd. gov. cn/kjzx_n/mtjj/content/post_4745744.html.
[25] 全国数据资源统计调查工作组.全国数据资源调查报告(2024年)[R].北京:全国数据资源统计调查工作组,2024.
National Data Resources Statistical Survey Working Group. National data resources survey report (2024)[R]. Beijing: National Data Resources Statistical Survey Working Group, 2024.
[26] Steam硬件和软件调查[EB/OL].[2025-10-05].https://store.steampowered.com/hwsurvey/Steam-Hardware-Software-Survey-Welcome-to-Steam.
Steam hardware and software survey[EB/OL]. [2025-10-05]. https://store. steampowered. com/hwsurvey/Steam-Hardware-Software-Survey-Welcome-to-Steam.
[27] Tang Z Q, Zhang F M, Zhou X J, et al. Pricing model for dynamic resource overbooking in edge computing[J]. IEEE Transactions on Cloud Computing, 2023, 11(2): 1970-1984.
[28] Sabyasachi A S, Kabir H M D, Abdelmoniem A M, et al. A resilient auction framework for deadline-aware jobs in cloud spot market[C]// IEEE 36th Symposium on Reliable Distributed Systems, 2017.
[29] Al-Theiabat H, Al-Ayyoub M, Alsmirat M, et al. A deep learning approach for Amazon EC2 spot price prediction[C]// IEEE/ACS 15th International Conference on Computer Systems and Applications (AICCSA), 2018.
[30] Baughman M, Haas C, Wolski R, et al. Predicting Amazon spot prices with LSTM networks[C]// 9th Workshop on Scientific Cloud Computing, 2018.
[31] Li J C, Wan Q, Yu Z P. Research on network security algorithms in distributed computing environment[C]// SPIE Conference on International Conference on Internet of Things and Machine Learning (IoTML 2023), 2023.
[32] 杨明烜,洪学海,唐宏伟.基于任务资源需求预测的人工智能算力调度[J].高技术通讯,2024,34(5):475-485.
Yang Mingxuan, Hong Xuehai, Tang Hongwei. Artificial intelligence computing power cluster scheduling based on task resource demand prediction [J]. Chinese High Technology Letters, 2024, 34(5): 475-485.
[33] Guilloteau Q, Richard O, Robu B, et al. Controlling the injection of best-effort tasks to harvest idle computing grid resources [C]// 25th International Conference on System Theory, Control and Computing (ICSTCC), 2021.
[34] Duan X, Ye K J. Leftover: improving large language model inference efficiency by leveraging idle resources [C]// International Conference on High Performance Big Data and Intelligent Systems (HDIS), 2023.
[35] Sun J J, Yan Y J, Wang Z Y, et al. Privacy-preserving coordinated operation of cross-enterprise data centers [J]. Applied Energy, 2025, 383: 125343.
[36] 共绩算力.算了么闲时算力接入平台[EB/OL].[2025-10-08]. https://suanleme.cn.
Comnergy. Suanleme idle computing power accesses platform [EB/OL]. [2025-10-08]. https://suanleme.cn.
[37] 共绩算力.闲时算力调度平台[EB/OL].[2025-10-08]. https://suanli.cn.
Comnergy. Idle computing power scheduling platform [EB/OL]. [2025-10-08]. https://suanli.cn.
[38] 可思为,董萍,马铭宇,等.考虑风光荷时空互补的多能源绿色数据中心多目标配置方法[J].电力系统保护与控制,2024,52(22):22-33.
Ke Siwei, Dong Ping, Ma Mingyu, et al. A multi-objective allocation method for multi-energy green data centers considering wind, solar and load spatial-temporal complementarity [J]. Power System Protection and Control, 2024, 52(22): 22-33.
[39] 零克云.GPU算力租赁[EB/OL].[2025-10-08]. https://gpulink.cc/computility-market.
ZeroKe Cloud. GPU computing power rental[EB/OL]. [2025-

中国知网　https://www.cnki.net

10-08]. https://gpulink.cc/computility-market.
[40] 刘祎泽,向月.计及负荷转移需求响应的低碳数据中心光储容量优化配置[J].电力自动化设备,2024,44(7):149-155
Liu Yize, Xiang Yue. Optimal allocation of photovoltaic and storage capacity in low carbon data center considering load transfer demand response [J]. Electric Power Automation Equipment, 2024, 44(7): 149-155.
[41] 国网青海省电力公司.关于2025年9月代理购电价格的公告[EB/OL]. [2025-08-05]. https://csc-static.sgcc.com.cn:28888/omg-static/99308281750147514938600207141603.html.
State Grid Qinghai Electric Power Company. Announcement on the agent power purchasing price for September 2025[EB/OL]. [2025-08-05]. https://csc-static.sgcc.com.cn:28888/omg-static/99308281750147514938600207141603.html.
[42] Holtzman A, Buys J, Du L, et al. The curious case of neural text degeneration[PP/OL]. [2025-08-05]. https://arxiv.org/abs/1904.09751.
[43] Wilhelm P, Wittkopp T, Kao O. Beyond test-time compute strategies: advocating energy-per-token in LLM inference [C]// 5th Workshop on Machine Learning and Systems, 2025.
[44] Xiao C J, Cai J, Zhao W L, et al. Densing law of LLMs[J]. Nature Machine Intelligence, 2025, 7(11): 1823-1833.

付　智(2000—),男,博士研究生,主要研究方向:算电协同、算力调度。E-mail:fz@suanleme.cn
郑博文(2004—),男,博士研究生,主要研究方向:算电协同、算力负荷预测、分布式算力网络。E-mail:zhengbw22@mails.tsinghua.edu.cn
刘效辰(1994—),男,通信作者,助理教授,特别研究员,博士生导师,主要研究方向:柔性用能建筑、车辆与建筑能源互动、分布式能源资源调控。E-mail:lxc4@tsinghua.edu.cn

(编辑　王梦岩)

Method and Practice of Computing Power-Electric Power Coordination Based on Idle Computing Power Scheduling

FU Zhi[1,2], *ZHENG Bowen*[1], *LIU Xiaochen*[1], *CHENG Wei*[3], *ZHANG Tao*[1], *LIU Xiaohua*[1]
(1. Department of Building Science, Tsinghua University, Beijing 100084, China;
2. Beijing Gongji Technology Co., Ltd., Beijing 100080, China;
3. China Unicom Guangdong Branch, Guangzhou 510627, China)

Abstract: The continuous growth of energy consumption in data centers poses severe challenges to power systems. In particular, the real-time response requirements for large language model inference tasks generate significant electricity peak loads. Idle computing resources feature a large scale and spatio-temporal regulation flexibility, serving as high-potential resources for realizing computing power-electric power coordination. To fully exploit the flexibility regulation capability of idle computing power, this paper proposes a computing power-electric power coordination method based on idle computing power scheduling to achieve high stability and low cost for computing tasks. Firstly, the nonlinear "performance-power consumption" characteristics of a single graphics processing unit are analyzed. Secondly, a temporal-regional scheduling strategy oriented to idle computing power is constructed. Finally, engineering practical verification is conducted on a real idle computing power scheduling platform. The experimental results show that the temporal regulation reduces the total power consumption of the computing power system by more than 17%, the regional scheduling cuts computing costs by nearly 18%, and improves the regional green power utilization rate by approximately 20%. The proposed method achieves remarkable performance and possesses broad promotion potential in reducing computing energy consumption and boosting renewable energy utilization, which provides a feasible solution for the coordinated low-carbon development of new power systems and computing power networks.

This work is supported by Ministry of Industry and Information Technology of the People's Republic of China: "Cross-domain Task Orchestration System for Heterogeneous Computing Power", Beijing Municipal Natural Science Foundation of China (No. QY25032), and Youth Talent Support Program of China Association for Science and Technology (No. 2023QNRC001).

Key words: computing power-electric power coordination; artificial intelligence (AI); data center; computing power; scheduling; flexibility regulation

中国知网 https://www.cnki.net