

电网技术
Power System Technology
ISSN 1000-3673,CN 11-2410/TM

《电网技术》网络首发论文

题目：支撑算电协同的异构数据中心深度学习任务两阶段能耗预测方法
作者：范俊秋，刘明顺，王明阳，马覃峰，吴启迪，安甦，黎灿兵
DOI：10.13335/j.1000-3673.pst.2026.0578
收稿日期：2026-08-20
网络首发日期：2026-09-24
引用格式：范俊秋，刘明顺，王明阳，马覃峰，吴启迪，安甦，黎灿兵．支撑算电协同的异构数据中心深度学习任务两阶段能耗预测方法[J/OL]．电网技术.
https://doi.org/10.13335/j.1000-3673.pst.2026.0578



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-09-24 14:13:35　网络首发地址：https://link.cnki.net/urlid/11.2410.TM.20260924.1009.001

电　网　技　术
Power System Technology

文章编号：1000-3673（2026）01-0001-07　中图分类号：TM73　文献标志码：A　学科代码：470·4051

支撑算电协同的异构数据中心深度学习任务两阶段能耗预测方法

范俊秋[1,2]，刘明顺[1]，王明阳[1]，马覃峰[1]，吴启迪[1]，安甦[1]，黎灿兵[2]

（1. 贵州电网有限责任公司，贵州省 贵阳市 550002）

（2. 上海交通大学电气工程学院，上海市 闵行区 200240）

A Two-stage Energy Consumption Prediction Method for Deep Learning Tasks in Heterogeneous Data Centers to Support Computing-power Coordination

FAN Junqiu[1,2], LIU Mingshun[1], WANG Mingyang[1], MA Qinfeng[1], WU Qidi[1], AN Su[1], LI Canbing[2]

(1. Guizhou Power Grid Co., Ltd., Guiyang 550002, Guizhou Province, China;

(2. School of Electrical Engineering, Shanghai Jiao Tong University, Minhang District, Shanghai 200240, China)

ABSTRACT: With the explosive growth of deep learning applications, data centers have become important adjustable load resources in power systems. However, the existing energy consumption prediction for data centers remains at the coarse-grained level of server and rack grades, and lacks effective means for a priori prediction and online calibration of the energy consumption of deep learning tasks, making it difficult to carry out refined computing-electricity collaborative scheduling. Therefore, this paper proposes a two-stage energy consumption prediction method for deep learning training tasks in heterogeneous data centers. In the first stage, based on historical data, a nonlinear energy consumption evaluation model with task information as input is constructed; hardware families are classified according to GPU(graphics processing unit) architectures and independent training is conducted for each family, so as to realize the preliminary a priori estimation of energy consumption across tasks and hardware, which provides support for the resource pre-allocation of training tasks in the scheduling center. In the second stage, during the task training process, through real-time energy consumption monitoring over a small number of epochs, an accurate long-cycle energy consumption prediction for training tasks is achieved based on the method of online residual state space calibration and locally weighted regression, which facilitates the real-time optimization of resource allocation in the scheduling center. Experimental results based on a diverse set of training tasks, including object detection, image classification, and text classification, demonstrate that, compared with traditional regression models, the mean absolute percentage error (MAPE) of the a priori prediction is reduced from approximately 13.0% to around 6%. With the incorporation of the online calibration mechanism, the total energy consumption prediction errors for short-term and long-term horizons are maintained at approximately 1% and 3%~4%, respectively, while the overall error remains around 2% in data center simulation scenarios. These results indicate that the proposed method achieves stable accuracy and strong generalization capability across different task types and heterogeneous hardware platforms.

KEY WORDS: data center; deep learning training; energy consumption prediction; online calibration; state-space model; computing-power coordination

摘要：随着深度学习应用的爆发式增长，数据中心正成为电力系统中重要的可调负荷。然而，现有数据中心的能耗预测多停留在机架级、服务器级的粗粒度层面，缺乏对深度学习任务能耗的事先预测与在线校准手段，难以开展精细化的算电协同调度。因此，提出一种面向异构数据中心深度学习训练任务的两阶段能耗预测方法：第一阶段基于历史数据，构建以任务信息为输入的非线性能耗评估模型，按图形处理器(graphics processing unit，GPU)架构划分硬件族并开展独立训练，实现跨任务、跨硬件的能耗事先初步估计，为调度中心的训练任务资源预分配提供支撑；第二阶段在任务训练过程中，通过少量轮数的实时能耗监测，基于在线残差状态空间校准与局部加权回归的方法，实现训练任务长周期的能耗精准预测，助力调度中心实时优化资源分配。基于覆盖目标检测、图像分类与文本分类等多类型训练任务的实测结果表明：相较于传统回归模型，事先预测的平均绝对百分比误差(mean absolute percentage error，MAPE)由约 13.0%降至约 6%水平；结合在线校准机制后，短周期与长周期总能耗预测误差分别

基金项目：中国南方电网公司重点科技项目(GZKJXM20240566)；贵州省高层次人才培养支持工程科技创新领域人才计划(KJLYRC-[2026]100)。

Project Supported by Key Science and Technology Project of China Southern Power Grid Co., Ltd. (GZKJXM20240566); Guizhou Province High-level Talent Training Support Program for Scientific and Technological Innovation Talents (KJLYRC-[2026]100).

稳定在约 1%和 3%~4%区间，在数据中心仿真场景中整体误差约为 2%。结果表明，该方法在跨任务、跨硬件场景下均具备稳定精度与良好泛化能力。

关键词：数据中心；深度学习训练；能耗预测；在线校准；状态空间模型；算力-电力协同

DOI：10.13335/j.1000-3673.pst.2026.0578

0 引言

近年来，深度学习在计算机视觉、自然语言处理等领域得到广泛应用，对图形处理器(graphics processing unit，GPU)/人工智能(artificial intelligence，AI)加速算力的需求[1]持续增长。云服务商和互联网企业不断扩建数据中心，训练负载已成为数据中心电力消耗的重要来源[2]。在此背景下，数据中心逐渐演变为电力系统中的关键可调负荷[3]。其角色与虚拟电厂[4]或负荷聚合商类似，通过对算力负载时序与规模的调控参与电力市场出清与安全约束调度，实现算力需求与电力资源的协同优化[5]。一方面，算力运营方希望在满足业务性能约束的前提下降低训练任务能耗与运行成本；另一方面，电网侧希望能够根据电网状态和数据中心用能需求进行动态需求响应，分配更多清洁能源[6]。

实现上述目标的关键前提，是对深度学习训练任务能耗进行细粒度精准的能耗预测[7]，尤其是在训练初期利用少量训练轮次(epoch)预测完整训练过程的能耗走势[8]。在数据中心参与的需求响应场景下，训练能耗预测误差将直接影响电力调度决策，既会压缩安全裕度，还容易出现供电紧张、局部线路/变压器过载、电压不稳等问题，严重时诱发限电甚至负荷切除，构成安全威胁。相关研究已表明，新型柔性负荷预测[9]不确定性正成为电网调度的重要风险源。

现有数据中心能耗建模大致可分为服务器级、作业级和训练任务级 3 类。服务器级方法通常以 中央处理器(central processing unit，CPU)/GPU 利用率、温度或硬件计数器为输入，关注单机或部件功率估计，实时性较好，但缺乏任务语义[10-11]。作业级方法多基于作业脚本、资源与作业管理系统(resource and job management system，RJMS)和调度信息，面向高性能计算(high performance computing，HPC)场景开展作业功率预测与调度优化[12-14]，能够服务批处理决策，但特征粒度较粗，难以反映深度学习任务的模型结构、训练配置及能耗演化过程。训练任务级方法以训练过程监测为核心，可估算训练能耗或碳排放[15-16]，但多依赖训练早期的线性外推，在异构硬件和长周期场景下稳定性不足。

面向数据中心算电协同场景，调度系统既需要在任务提交阶段依据模型参数、硬件配置等易获取信息完成能耗事先评估和资源预分配，又需要在任务运行过程中结合实时监测持续修正预测结果，以支撑精细化需求响应。现有方法的不足主要体现在：1）缺少面向深度学习任务的先验建模，难以仅依赖任务参数和硬件配置形成可靠能耗估计；2）缺少事先评估与运行校准的预测机制，容易造成任务接纳失准、资源预留不足或过度配置；3）缺少基于小样本在线观测的动态校准能力，难以抑制长周期预测中的误差累积[17]。

针对上述问题，本文提出一种面向数据中心深度学习训练任务的两阶段能耗预测方法。该方法首先在训练开始前基于任务结构特征、硬件特征与系统配置特征建立跨任务、跨硬件的先验能耗预测模型；随后在训练初期利用少量 epoch 的实测功率数据，通过在线校准机制对预测结果进行动态修正，从而实现对中长期训练能耗的稳定预测。

本文的主要贡献如下：1）提出训练任务生命周期视角的两阶段能耗预测问题建模框架，明确训练前预测与运行期校准在算力调度与算力-电力协同中的作用关系；2）设计面向训练任务的先验能耗预测方法，通过任务结构建模与硬件族划分，提高跨任务、跨硬件场景下的预测泛化能力；3）提出小样本在线校准机制，在仅监测少量训练轮数的条件下，实现对长周期训练能耗的稳定预测，从而降低预测误差在系统级资源调度中的扩散风险。

1 相关研究进展

本节从服务器级、作业级/集群级以及深度学习训练任务级 3 个层面，综述数据中心能耗建模与预测的代表性研究，并分析其适用场景与局限性，为本文方法设计提供背景支撑。

1.1 服务器级能耗建模方法

服务器级能耗建模通常以单台服务器或单块 CPU/GPU 为研究对象，通过硬件性能计数器或资源利用率构建功率估计模型。早期研究多采用多元线性回归，将指令数、缓存访问和内存带宽等指标映射到整机功率[18]；后续工作通过引入高阶多项式或非线性回归[19-20]，提高了在高负载场景下的预测精度。近年来，也有研究利用多项式模型或混合模型对服务器功率进行更精细分解[21]。

在云和虚拟化环境中，部分方法基于虚拟机或容器层面的 CPU、内存和网络利用率，训练机器学

习模型以估算实例对应的物理能耗，用于能耗计费和资源调度。

服务器级模型实现简单、实时性好，是数据中心能耗监测的基础。但其局限在于：1）缺乏任务语义，无法针对训练任务进行能耗预测；2）平台相关性强，模型难以适应不同的硬件[22]。

1.2 作业级与集群级能耗预测方法

作业级能耗预测主要服务于 HPC 与批处理系统调度，研究对象从单机扩展至“作业－节点”层面。Saillant[23]等基于作业管理系统日志，利用节点数、核数、队列信息等作业元数据，在作业提交阶段预测其平均功率，用于功率约束调度与能耗优化。Antici[24]等进一步引入在线学习机制，结合运行期监控数据动态更新模型参数，以适应负载变化。

作业级方法的优势在于预测结果可直接用于调度决策，并可在一定程度上支持在线修正。然而，其局限性同样明显：1）作业特征多为粗粒度资源描述，缺乏对深度学习模型结构和训练配置的刻画；2）预测目标多为作业整体平均功率，难以描述能耗随训练进程的演化；3）早期运行数据通常仅用于经验修正，未系统建模其对长期预测的影响。

1.3 深度学习训练任务能耗估计与能效优化

针对深度学习训练任务，近年来出现了一系列能耗与碳排放估计工具。Anthony 等提出 Carbontracker 工具，通过监测训练初期若干 epoch 的功率和运行时间，对整体训练能耗进行线性预测；CodeCarbon 等工具则结合硬件功率估算与区域碳强度数据，提供通用碳排放估计。这类工具提高了训练能耗的可见性，但在异构硬件和复杂训练过程下，预测误差较大，更适合粗粒度环境评估[25]。

Del Rey 等从模型架构与训练配置角度出发，引入卷积层统计、参数规模和运行环境特征，提出相较 FLOPs 更精细的能耗估算方法，在特定任务族中取得较好效果[26]。然而，这类方法多依赖离线拟合，且泛化能力和在线自适应能力有限。

从系统优化视角，Zeus 框架提出“能耗–精度”权衡指标，并通过动态调整 batch size(批大小)和 GPU 功率上限提升训练能效。这类方法强调配置优化而非能耗预测本身，难以直接用于给定配置下的任务级能耗前瞻预测。

另有研究从宏观估算大模型训练碳足迹，或通过标准化框架核算通用计算碳排放[27-28]，其多用于环境评估与政策建议，对数据中心单个训练任务的精细预测与调度支撑不足[29-30]。

综上，现有研究在不同层级对数据中心能耗建模提供了重要基础[31]：服务器级方法具备实时性但缺乏任务语义；作业级方法支持调度决策但特征粒度较粗；训练任务级工具提升了能耗透明度，但多依赖线性预测，难以在异构硬件与长周期场景下保持稳定精度。表 1 对服务器级、作业级、集群级以及训练任务级能耗建模方法进行了总结。

表 1 不同层级能耗建模方法的对比

Table 1 Comparison of energy consumption modeling methods at different levels

方法类别	面向场景	主要思路	特点
服务器级方法	单机/部件功率监测	基于利用率、温度、计数器等估计设备功率	缺乏任务语义，难以支撑算电协同调度
作业级方法	HPC/集群作业调度	基于作业脚本、日志、资源申请信息预测作业功率	特征粒度较粗，难以刻画深度学习训练过程的能耗
训练任务级方法	训练总耗/碳排放估计	基于训练早期功率或能耗数据外推总能耗	误差易积累导致预测结果偏差较大
本文方法	数据中心的算电协同	训练前先验估计+训练中动态调整	事先评估结果支撑资源的预分配，实时动态评估支撑精细化的调度

本文面向异构数据中心深度学习训练任务的能耗预测，在上述研究之间引入两阶段建模思路：训练前基于任务结构与硬件特征构建跨任务、跨硬件的非线性先验模型，训练初期利用少量 epoch 的实测数据进行在线校准，并通过状态空间模型实现中长期预测。该方法兼顾工程需求与预测精度，为后续的能耗感知调度与算力-电力协同优化提供任务级预测基础。

2 两阶段深度学习任务能耗预测方法

2.1 场景与问题定义

在云端 AI 数据中心中，深度学习训练任务以 GPU/AI 加速服务器为主要执行载体。调度系统在任务提交阶段需要估计不同硬件配置下的训练能耗，以支持任务接纳、资源分配和能耗感知调度；在训练运行过程中，则需要基于有限的实时观测数据对能耗预测进行动态校准。

设训练任务为 τ，其计划执行的总训练轮数为 $N(\tau)$。在给定硬件配置 h 下，第 e 个 epoch 的能耗记为 $E_{\tau,h}(e)$，则训练任务的总能耗为

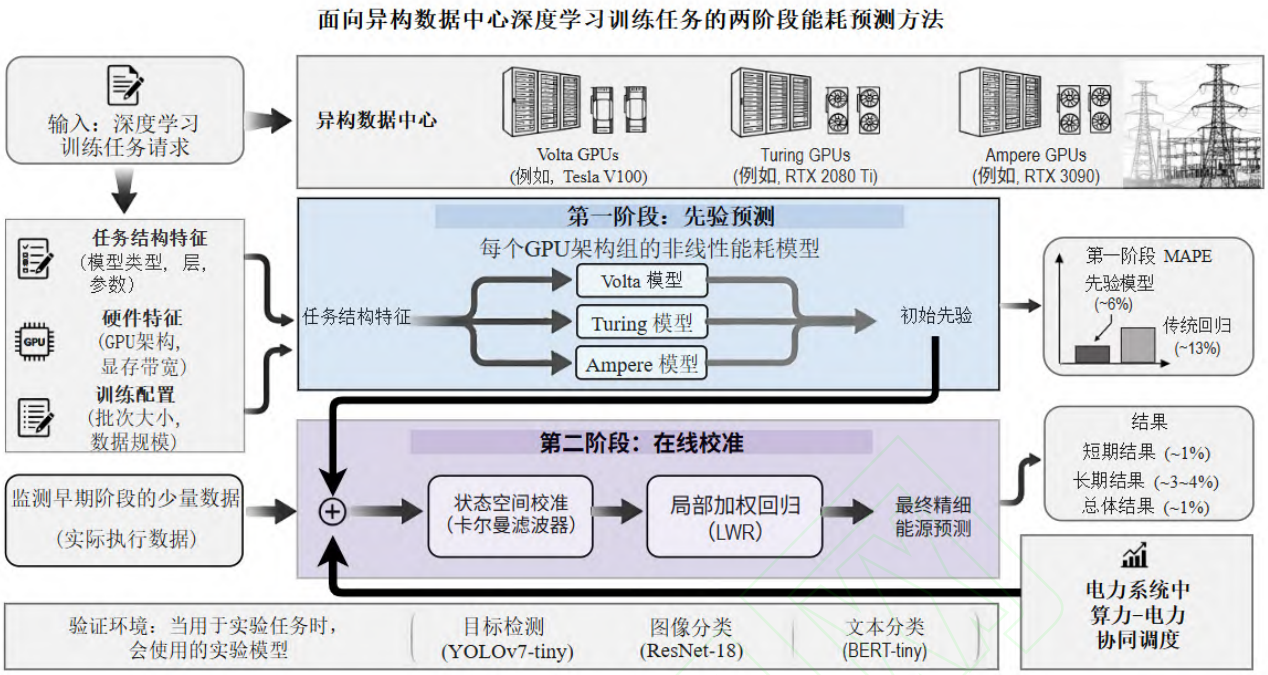


图 1 两阶段方法框架

Fig. 1 Architecture diagram of the two-stage energy consumption prediction method

$$E_{\tau,h}^{\text{total}} = \sum_{e=1}^{N(t)} E_{\tau,h}(e) \tag{1}$$

为刻画影响训练能耗的关键因素，引入以下 3 类特征向量：

1）任务特征向量：包括模型类型、层数、参数规模、输入尺寸或序列长度、主要算子等。

2）硬件特征向量：包括架构代际、显存容量、显存带宽、默认功率上限等。

3）配置特征向量：包括 batch size、数据规模、训练轮数等。

需要说明的是，本文重点研究任务级能耗预测，而不是完整的算力-电力-通信联合调度。预测模块本身仅涉及任务元数据、硬件配置和少量早期能耗观测值的传输，通信开销相对较小；当预测结果进一步用于任务迁移、跨节点训练或跨数据中心调度时，通信成本应作为下游调度模型中的带宽、时延和迁移数据量约束统一考虑。本文输出的任务功率/能耗预测结果可作为此类调度模型的基础输入，通信约束下的联合优化将在后续工作中进一步研究。

本文关注的问题可形式化为：在训练开始前，基于任务、硬件特征给出事先能耗预测；在仅观测前 k 个 epoch 实测数据的条件下，对后续训练过程能耗进行稳定预测。

2.2 两阶段能耗预测总体框架

深度学习训练任务的能耗形成机制复杂，不同任务类型、硬件平台和运行状态之间存在显著的非线性耦合关系。若仅依赖静态特征建立统一模型，难以准确表征异构设备上的动态能耗变化；若完全依赖运行期观测，又无法满足任务调度阶段对事先评估和资源预分配的需求。

因此，本文采用两阶段预测框架，通过这种“先估计、再修正”的方式，可以在保证调度阶段可用性的同时，提高运行阶段的预测精度。其核心流程如图 1 所示。

1）事先预测阶段(Stage-1)。

在训练开始前，基于历史任务-硬件运行数据，构建跨任务、跨硬件的先验能耗模型，为任务接纳与初始调度提供能耗估计。

2）在线校准阶段(Stage-2)。

在训练初期采集少量 epoch 的实测能耗数据，基于在线残差状态空间校准与局部加权回归的方法，实现训练任务长周期的能耗精准预测，并实时调整模型对预测结果进行快速校准。

2.3 阶段一：事先能耗预测模型

2.3.1 任务与硬件特征表示

将任务、硬件与配置特征拼接为统一输入向量：

$$\boldsymbol{x}=\left[\ \boldsymbol{x}_{\text{task}},\ \boldsymbol{x}_{\text{hw}},\boldsymbol{x}_{\text{cfg}}\ \right] \tag{2}$$

式中：$\boldsymbol{x}_{\text{task}}$ 为任务特征向量，包括模型类型、层数、参数规模、算子等；$\boldsymbol{x}_{\text{hw}}$ 为硬件特征向量，包括架构代际、显存容量、带宽、功率上限等；$\boldsymbol{x}_{\text{cfg}}$ 为配置特征向量。任务特征的核心是模型的计算特征。通过分析模型计算图，统计单个 epoch 中各类算子的调用次数，构建操作向量：

$$\boldsymbol{o}=\left[\boldsymbol{o}_1,\boldsymbol{o}_2,\ldots,\boldsymbol{o}_m\right] \tag{3}$$

式中：$\boldsymbol{o}_i$ 为第 i 类核心算子在单个训练轮次内的调用次数；m 为所统计的核心算子类别总数，即操作向量的维数。

为刻画能耗与操作数量之间的非线性关系，引入多项式扩展特征：

$$\boldsymbol{o}=\left[\boldsymbol{o}^0,\boldsymbol{o}^2,\boldsymbol{o}^3\right] \tag{4}$$

2.3.2 非线性操作级能耗模型

单个 epoch 的节点级能耗可分解为计算能耗与系统开销能耗两部分：

$$E_e=E_e^{\text{comp}}+E_e^{\text{sys}} \tag{5}$$

式中：E_e^{comp} 为由模型结构与硬件微架构决定的计算能耗；E_e^{sys} 为由配置与硬件特征决定的系统开销能耗。计算能耗由模型操作结构与硬件微架构特性共同决定，本文基于操作级统计特征构建前馈神经网络模型做回归建模。单个训练任务单 epoch 的操作向量维度 m 取决于对目标任务族中核心耗能算子的覆盖程度；经二阶多项式扩展构造非线性输入特征后，网络输入维度 M 需兼顾模型的表达能力与计算开销，将该特征向量与对应硬件特征拼接作为模型输入，计算能耗映射函数表示为

$$E_e^{\text{comp}}=f_{\theta_f}(\phi(\mathbf{o}_e),\boldsymbol{h}) \tag{6}$$

式中：$\phi(\cdot)$ 为多项式特征映射；$\boldsymbol{h}$ 为硬件特征向量；$\boldsymbol{\theta}_f$ 为模型参数。

该前馈神经网络采用两层隐藏层结构，节点数分别为 64 与 32，层间均用修正线性单元(rectified linear unit，ReLU)激活函数增强非线性表达能力，输出层为线性回归单元；模型基于 320 组历史任务-硬件运行样本训练，以均方误差为损失函数，通过 Adam 优化算法更新参数。

考虑 GPU 架构差异对能效特性的影响，本文按显卡架构代际将硬件划分为多个独立硬件族：Volta(如 V100)、Turing(如 RTX 2080 Ti)等。为每一硬件族的训练任务单独训练对应神经网络模型参数，捕捉族内一致的能耗映射规律。

系统开销能耗部分建模为配置特征与硬件特征的非线性函数：

$$E_e^{\text{sys}}=g_{\psi_f}(\boldsymbol{x}_{\text{cfg}},\boldsymbol{h}) \tag{7}$$

式中：g_{ψ_f} 为硬件族 f 对应的系统开销能耗非线性映射函数；ψ_f 为该映射函数的模型参数；$\boldsymbol{h}$ 为硬件特征向量。

从而得到阶段一的逐轮能耗预测结果：

$$\hat{E}_e=E_e^{\text{comp}}+E_e^{\text{sys}} \tag{8}$$

该族内建模与簇间迁移策略在保证模型表达能力的同时，有效提升了跨硬件环境下事先能耗预测的泛化稳定性。

在实际数据中心环境中，训练任务能耗还会受到显存带宽、功率限制机制、散热条件以及节点负载波动等多种运行时因素影响。这些因素在任务执行前通常难以准确获取或建模，因此本文在 Stage-1 中采用“GPU 架构级硬件族划分”的方式构建基础能耗映射关系，从而获得稳定的先验预测结果。随后，在 Stage-2 中通过少量 early-epoch 的实时观测数据与状态空间模型进行在线校准，使模型能够逐步吸收运行环境带来的偏差，从而提高最终预测精度。

2.3.3 硬件族级建模与迁移

针对每一硬件族，利用历史数据独立训练模型参数，以平衡模型表达能力与跨硬件泛化能力。对族内训练残差估计每轮能耗的方差：

$$\sigma_f^2=\frac{1}{n_f}\sum_{i=1}^{n_f}\left(E_i-\hat{E}_i^{(1)}\right)^2 \tag{9}$$

式中：E_i 为历史数据中，该硬件族在训练第 i 轮时的真实能耗；$\hat{E}_i^{(1)}$ 为第一阶段非线性能耗模型给出的预测值；n_f 为硬件族所包含的有效历史逐轮能耗样本数。

该方差作为 Stage-1 预测不确定性的量化结果，为 Stage-2 的贝叶斯校准提供先验基础。

2.4 阶段二：实时能耗预测与在线校准

2.4.1 早期运行观测

在 Stage-1 提供的先验预测基础上，Stage-2 利

用训练初期少量 epoch 的运行观测数据对能耗预测进行动态校准。在训练前 k 个 epoch 内，监控系统记录平均功率与运行时间，并计算实测能耗：

$$E(e)=P(e)T(e) \tag{10}$$

式中：$E(e)$ 为第 e 个训练轮次的实测能耗；$P(e)$ 为该训练轮次内的平均功率；$T(e)$ 为该训练轮次的运行时间。

对早期运行特征进行聚合，构造均值与变化趋势等时间无关统计量，作为可用于未来预测的输入特征。

2.4.2 基于可预见特征的局部回归

建模的每轮能耗为

$$E(e)=\hat{E}^{(1)}(e)+\boldsymbol{z}(e)^{\mathrm{T}}\theta+\varepsilon_e \tag{11}$$

式中：$\hat{E}^{(1)}(e)$ 为第一阶段模型给出的该轮先验能耗预测值；$\boldsymbol{z}(e)$ 为由训练轮次位置、配置特征和早期运行统计量构成的局部回归特征向量；θ 为局部回归系数向量；ε_e 为第 e 个训练轮次的随机误差项。$\boldsymbol{z}(e)$ 仅包含 epoch 位置、配置特征和早期统计特征。通过带正则化的最小二乘求解局部参数，实现对任务特定偏移的快速校准。

2.4.3 残差的线性状态空间建模

为抑制长预测窗口的误差累积，本文将局部回归校准后的残差序列建模为线性状态空间模型，采用卡尔曼滤波递推估计与预测。设系统状态向量含残差平稳项与趋势项，模型表示为

$$\boldsymbol{x}_{e+1}=\boldsymbol{A}\boldsymbol{x}_e+\boldsymbol{w}_e,\quad \boldsymbol{w}_e\sim \mathrm{N}(0,\boldsymbol{Q}) \tag{12}$$

$$\boldsymbol{r}_e=\boldsymbol{H}\boldsymbol{x}_e+\boldsymbol{v}_e,\quad \boldsymbol{v}_e\sim \mathrm{N}(0,\boldsymbol{R}) \tag{13}$$

式中：$\boldsymbol{Q}$ 与 $\boldsymbol{R}$ 分别为过程噪声协方差与观测噪声协方差，用于刻画残差演化不确定性与测量误差水平；$\boldsymbol{A}$ 为状态转移矩阵，描述残差平稳项与趋势项从第 e 个训练轮次到第 $e+1$ 个训练轮次的演化关系；$\boldsymbol{H}$ 为观测矩阵，将状态向量 $\boldsymbol{x}_e$ 映射为可观测的校准残差 $\boldsymbol{r}_e$。

工程实现中，先依据历史统计方差初始化 $\boldsymbol{Q}$，结合训练初期噪声与误差水平设定 $\boldsymbol{R}$ 初始值，保障滤波器早期动态响应合理性。在线校准时引入滑动时间窗协方差自适应更新机制，动态修正 $\boldsymbol{Q}$ 与 $\boldsymbol{R}$：

$$\boldsymbol{Q}_e=\mathrm{Cov}(r_{e-L:e}) \tag{14}$$

$$\boldsymbol{R}_e=\mathrm{Var}(y_{e-L:e}-\hat{y}_{e-L:e}) \tag{15}$$

式中：L 为窗口长度；y_{e} 与 $\hat{y}_e$ 分别为实测与预测能耗。该策略可使滤波器根据训练阶段波动特性，自适应调整对预测与观测数据的信任权重，在负载波动或噪声升高时维持预测稳定性。

2.4.4 误差平衡与总能耗估计

综合先验不确定性与早期观测方差，引入权重系数：

$$\alpha=\frac{\sigma_f^2}{\sigma_f^2+\sigma_{\mathrm{obs}}^2} \tag{16}$$

式中：σ_f 为硬件族 f 的第一阶段预测残差方差；σ_{obs} 为根据前 k 个训练轮次的观测残差估计得到的方差

最终总能耗预测由先验预测与在线校准结果加权得到：

$$\hat{E}_{\mathrm{total}}=\alpha\hat{E}_{\mathrm{prior}}+(1-\alpha)\hat{E}_{\mathrm{online}} \tag{17}$$

式中：α 为权重系数，用于平衡先验可靠性与观测稳定性；$\hat{E}_{\mathrm{total}}$ 最终输出的总能耗预测值；$\hat{E}_{\mathrm{prior}}$ 来自第一阶段的先验预测；$\hat{E}_{\mathrm{online}}$ 来自第二阶段的在线校准结果。该机制在先验可靠性与观测稳定性之间实现自适应平衡，避免少量异常观测导致预测失稳。

3 实验设置

3.1 实验目标

为验证本文提出的两阶段能耗预测方法在异构 GPU 不同类型训练任务场景下的有效性，重点考察以下 4 个方面：1）验证第一阶段事先预测模型在不同训练任务、不同 GPU 平台下的预测能力，分析其在训练开始前能否给出稳定、可用的能耗先验。2）验证第二阶段在线校准模型在仅观测训练初期少量训练轮次的条件下，对短周期和长周期累计能耗预测的提升效果，分析其对误差累积的抑制能力。3）分析自适应更新策略对不同硬件特征变化和过程噪声对自适应模型的影响程度。4）考察

不同预测方法在固定功率预算约束下的支撑效果，分析其对数据中心峰值估计、预算越界和任务接纳判断的影响。

3.2 实验对象与平台配置

3.2.1 训练任务与数据集

本文选取目标检测、图像分类和文本分类:3 类代表性训练任务进行验证。3 类任务分别对应视觉检测、视觉识别和 Transformer 文本建模等典型深度学习负载，在模型结构、输入形态、算子组成和训练动态方面具有差异性，可用于初步验证所提方法的跨任务泛化能力，在本文研究的任务级能耗建模框架下具有较好的代表性，其基本信息如表 2 所示。实际数据中心还可能包含推荐、语音、机器翻译、生成式模型训练/微调、推理服务及传统 IT 负载等任务，后续可通过扩展任务模板和特征库纳入本文框架。

表 2 代表性训练任务与数据集设置

Table 2 Representative training tasks and dataset settings

任务类型	模型	数据集
目标检测	YOLOv7-tiny	PASCAL VOC 2007+2012
图像分类	ResNet-18	CIFAR-10
文本分类	BERT-tiny	AG News

其中：ResNet-18 是 torchvision 提供的标准残差网络模型；CIFAR-10 是经典小尺寸图像分类数据集，图像大小为 32×32，共 10 个类别。BERT 模型 bert_uncased_L-2_H-128_A-2 采用 2 层 Transformer、128 维隐藏层和 2 个注意力头，模型卡明确将其定位为面向受限计算资源环境的紧凑型 BERT 变体；AG News 常见公开版本包含 120,000 条训练样本和 7600 条测试样本，共 4 个新闻类别。

3.2.2 硬件平台与训练配置

为模拟数据中心中训练任务的多样性，实验通过联合调整训练数据规模与 batch size 构造轻载、中载与重载:3 类负载强度。实验平台由 3 类 GPU 组成：Tesla V100、RTX 2080 Ti 和 RTX 3090，分别对应数据中心级 Volta、消费级 Turing 和消费级 Ampere3 类硬件族。

在训练配置上，3 类任务统一采用如下扰动方式：

1）batch size：16、32、64。

2）precision：FP32、自动混合精度(automatic mixed precision，AMP)。

3）数据规模：25%、50%、100%。

每组配置重复运行 3 次，结果取均值。

3.2.3 能耗采集与训练轮次统一

训练过程中，以 1s 为周期记录 GPU 功率，并同步保存训练日志，提取每个训练轮次的开始时间、结束时间和运行时长。

为兼容视觉训练与文本微调任务，本文将训练轮次作为统一的时间粒度。对于 YOLOv7-tiny 和 ResNet-18，1 个训练轮次对应 1 个 epoch；对于 BERT-tiny，考虑其单个 epoch 较短，本文将连续若干个 optimizer steps 聚合为 1 个训练轮次。这样处理后，不同任务都可以在统一的 k 和 H 定义下进行比较，其中：k 表示已观测训练轮次数；H 表示预测终止训练轮次数。

3.3 输入特征、对比方法与实验分组

3.3.1 输入特征

第一阶段事先预测使用 3 类输入特征：

1）任务结构特征：包括模型类型、层数、参数规模、输入尺寸或序列长度、主要算子统计等。

2）硬件特征：包括架构代际、显存容量、显存带宽、默认功率上限等。

3）训练配置特征：包括 batch size、数据规模、训练轮数等。

第二阶段在线校准在上述先验特征基础上，进一步引入前 k 个训练轮次的平均能耗、趋势项和残差统计量，用于构建局部回归和残差状态空间模型。

3.3.2 对比方法

为系统评估不同能耗预测策略的有效性，本文设置 4 类代表性方法进行对比：

1）Baseline[32]：基于 FLOPs 的线性能耗估计，通过最小二乘拟合每 GFLOPs 对应的能耗常数。

2）Carbontracker：基于 Carbontracker 的算法，利用前 k 个 epoch 的平均能耗对后续训练过程进行线性推理。

3）Stage-1-only：为分析在线校准阶段的贡献，仅使用本文第一阶段模型而不进行 Stage-2 在线校准，用于说明两阶段机制带来的精度提升。

4）Two-Stage：本文方法，Stage-1 生成结构先验，Stage-2 在训练初期小样本观测基础上进行在线校准，并对中长期能耗进行推理。

3.3.3 实验分组

为系统评估不同能耗预测策略的有效性，本文设置 5 组实验，如表 3 所示。

表 3 实验分组设置

Table 3 Experimental group settings

实验内容	主要目的	对应章节
第一阶段跨任务、跨硬件预测实验	验证事先预测能力	4.1
第二阶段短/长周期预测实验	验证在线校准能力	4.2
硬件特征消融实验	分析硬件连续特征的作用	4.3
状态空间策略实验	分析自适应噪声更新的作用	4.4
功率预算代理实验	分析预测结果对预算判断的影响	4.5

3.4 场景设置与评价指标

3.4.1 短周期与长周期预测场景

为兼顾“快速评估”和“中长期预算”两类算电协同需求，本文设置短周期与长周期两组典型情形(S1/S2/L1/L2)，用于统一比较不同方法在不同预测窗口长度下的表现，预测场景设置如表 4 所示。

表 4 预测场景设置

Table 4 Prediction scenario settings

场景编号	监测轮数（k）	预测终止轮数（H）	说明
S1	3	10	极小样本、短周期预测
S2	5	10	增加少量样本的短周期预测
L1	5	50	中等长度预测窗口
L2	5	100	长预测窗口，考察误差累积

3.4.2 评价指标

任务级能耗预测精度采用平均绝对百分比误差(mean absolute percentage error，MAPE），用于刻画预测值与实测值之间的相对偏差，便于跨硬件平台进行统一对比：

$$\eta_{\mathrm{MAPE}}=\frac{1}{n}\sum_{i=1}^{n}\left|\frac{\hat{E}_i-E_i}{E_i}\right|\times 100\% \tag{18}$$

式中：η_{MAPE}为平均绝对百分比误差；n为 epoch 数；$\hat{E}_i$与E_i分别表示第i轮 epoch 的预测能耗与实测能耗。Stage-1 与 Stage-2 的所有任务级对比均以该指标作为主评价标准，以保证不同预测策略间的可比性。

3.4.3 功率预算代理实验设置

功率预算代理实验基于实测任务模板构造一个滚动调度窗口[33]。具体做法是：将前述 3 类任务在 3 GPU 上形成的实测样本作为任务库，在给定时间窗口内按泊松过程生成任务到达序列；当某一任务到达时，调度器根据预测得到的任务能耗与短期平均功率，判断其加入后是否会使系统总功率超过预算。若超过则将任务延后；否则予以接纳执行。

对于功率预算代理实验，本文引入以下 4 个指标[34]：1）峰值功率误差，反映了预测方法对峰值预算的估计偏差；2）预算越界率，在固定功率上限下，实际功率超过预算的时间占比；3）误接纳率，预测认为可接纳、但实际执行后超预算的任务比例；4）误拒绝率，预测认为不可接纳、但实际本可在预算内运行的任务比例。

4 实验结果与分析

4.1 第一阶段：跨任务、跨硬件的事先预测结果

本节首先在 3 类 GPU 平台上验证两阶段方法的预测精度。表 5 给出了第一阶段在 3 类任务和 3 类 GPU 上的事先预测误差。整体来看，FLOPs 在所有任务和硬件组合上都存在较明显偏差，而第一阶段模型在 9 组组合上均取得了更低误差。

表 5 Stage-1 第一阶段事先预测误差(MAPE，%)

Table 5 A priori prediction errors of stage-1 (MAPE, %)

	Tesla (V100)		2080 Ti		RTX3090	
	Baseline	Stage-1-only	Baseline	Stage-1-only	Baseline	Stage-1-only
YOLOv7-tiny / VOC	10.9	4.3	15.1	7.9	11.8	5.1
ResNet-18 / CIFAR-10	11.7	4.8	16.3	8.4	12.9	5.7
BERT-tiny / AG News	13.8	5.7	18.6	9.1	15.2	6.2

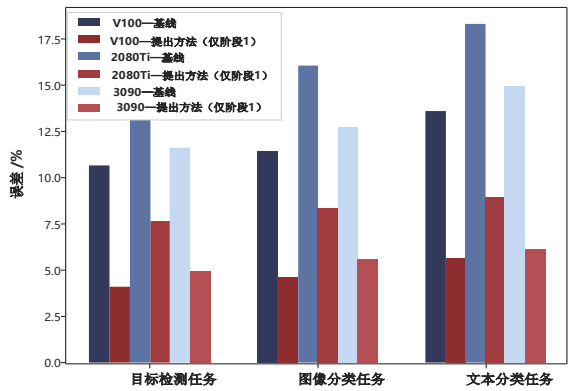


图 2 第一阶段跨任务与跨 GPU 性能对比

Fig. 2 Cross-task and cross-gpu performance comparison of stage-1 model

从任务角度看，如图 2 第一阶段跨任务与跨 GPU 性能对比图所示，YOLOv7-tiny 和 ResNet-18 上的误差水平较为接近，说明第一阶段对两类视觉任务都具有较稳定的先验刻画能力。BERT-tiny 的误差整体略高，这表明 Transformer 结构在输入组织方式、参数交互模式和访存行为上与卷积模型存在差异，使得训练前静态建模难度进一步增加；但即便如此，第一阶段相较 FLOPs 仍然获得了明显提升。

从硬件角度看，2080 Ti 上的误差高于 V100 和 3090，说明在消费级 Turing 平台上，能耗受训练配置和硬件边界条件耦合的影响更明显。3090 的结果介于 V100 与 2080 Ti 之间，说明第一阶段模型在扩展到第三类 GPU 后仍能保持较好的稳定性。

4.2 第二阶段：短周期与长周期预测结果

4.2.1 总体结果

表 6 不同场景下的平均总能耗预测误差（MAPE，%）

Table 6 Overall prediction errors of total energy consumption under different scenarios (MAPE, %)

场景	场景编号	k	H	Stage-1-only	Carbontracker	Two-Stage
场景 1	S1	3	10	6.6	3.1	1.5
场景 2	S2	5	10	6.0	2.4	1.0
场景 3	L1	5	50	9.4	4.9	2.9
场景 4	L2	5	100	12.7	6.8	4.0

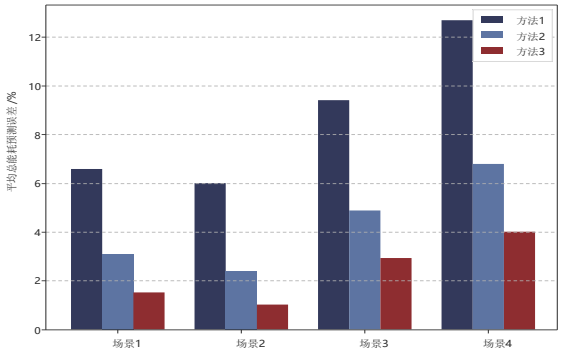


图 3 不同预测方法在短/长周期场景下的对比结果

Fig. 3 Comparison of different prediction methods under short-term and long-term scenarios

表 6 给出了 4 种预测场景下不同方法的平均总能耗预测误差。可以看出，随着预测窗口从短周期扩展到长周期，Stage-1-only 的误差增长最明显，CarbonTracker 虽然优于纯先验模型，但在长窗口下仍有较明显误差累积；相比之下，Two-Stage 在 4 种场景下均保持最优。不同预测方法在短/长周期场景下的对比结果如图 3 所示。

在短周期场景 S1 和 S2 中，Two-Stage 分别将平均误差降低到 1.5%和 1.0%，表明少量观测已经能够显著修正第一阶段先验偏差。随着观测轮次由 3 增加到 5，CarbonTracker 与 Two-Stage 的误差均有下降，但 Two-Stage 始终保持更低水平，说明在短周期内，结构先验与在线校准的结合能够更快完成个体化修正。

在长周期场景 L1 和 L2 中，Two-Stage 之外的方法误差增长更明显。Stage-1-only 在 L2 场景下的平均误差达到 12.7%，说明仅依赖训练前静态信息无法准确描述较长训练过程中的动态变化；CarbonTracker-like 在 L2 场景下的误差为 6.8%，说明仅基于前若干轮平均值做线性外推时，预测窗口越长，误差越容易累积；Two-Stage 则将误差控制在 4.0%，说明在线残差建模能够有效缓解长窗口预测中的趋势漂移问题。

4.2.2 分任务结果

表 7 分任务不同场景下的平均总能耗预测误差（MAPE，%）

Table 7 Prediction error of average total energy consumption across different task scenarios (MAPE, %)

任务	场景	Stage-1-only	CarbonTracker	Two-Stage
YOLOv7-tiny / VOC	场景 2	5.5	2.0	0.8
YOLOv7-tiny / VOC	场景 4	11.4	6.1	3.4

ResNet-18 / CIFAR-10	场景 2	5.8	2.2	0.9
ResNet-18 / CIFAR-10	场景 4	11.8	6.4	3.7

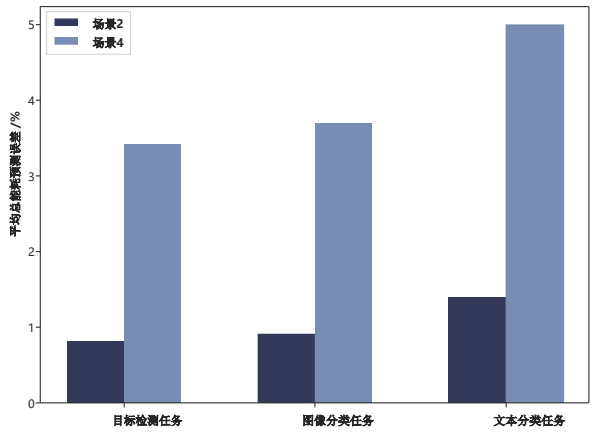


图 4 跨任务能耗预测误差对比

Fig. 4 Cross-task energy consumption prediction error comparison

由表 7 可见，Two-Stage 在 3 类任务上都取得了最优结果。YOLOv7-tiny 与 ResNet-18 的误差量级较为接近，说明该方法在两类视觉训练任务上具有较好的通用性。反映出序列模型训练过程中的动态特性更复杂；但 Two-Stage 相较其他基线的改进趋势仍然稳定存在。跨任务能耗预测误差对比如图 4 所示。

这说明，两阶段方法不仅能够在卷积类训练任务中发挥作用，在参数组织方式和训练行为差异更大的 Transformer 类任务上也具有可迁移性。

4.3 硬件特征消融实验

表 8 第一阶段硬件特征消融结果(平均 MAPE，%)

Table 8 Ablation results of hardware features in stage-1 (average MAPE, %)

特征内容	平均 MAPE
仅架构标签	7.5
架构标签 + 显存容量 + 默认功率上限	6.9
架构标签 + 显存容量 + 默认功率上限 + 显存带宽	6.4

第一阶段硬件特征消融结果如表 8 所示，仅使用架构标签时，第一阶段已经优于 FLOPs-Linear，但误差仍相对较高。加入显存容量和默认功率上限后，平均误差进一步下降，说明这些硬件连续特征能够提供比“硬件族标签”更细粒度的信息。进一步加入显存带宽后，误差继续下降，表明显存带宽对任务级训练能耗具有明显影响，尤其在不同代际 GPU 的比较中更为重要。

这一结果说明，第一阶段并非只能依赖粗粒度的硬件分族，而是可以通过引入连续硬件特征进一步增强跨硬件建模能力。

4.4 状态空间策略实验

表 9 不同状态空间策略在 L2 场景下的结果(平均 MAPE，%)

Table 9 Prediction errors of different state-space strategies under the l2 scenario (MAPE, %)

方法	说明	L2 MAPE
B0	仅局部回归，不使用状态空间模型	6.9
B1	局部回归 + 状态空间模型，($\boldsymbol{Q}$,$\boldsymbol{R}$)固定	5.6
B2	局部回归 + 状态空间模型，仅($\boldsymbol{R}$)自适应更新	4.8
B3	局部回归 + 状态空间模型，($\boldsymbol{Q}$,$\boldsymbol{R}$)同时自适应更新	4.0

不同状态空间策略在 L2 场景下的结果如表 9 所示，仅加入局部回归后，模型已经能够吸收部分任务个体偏移，但在长周期场景下误差仍然较高；当引入状态空间模型后，误差进一步下降，说明残差趋势建模对抑制长窗口误差累积具有明显作用；当 $\boldsymbol{R}$ 或 $\boldsymbol{Q}$、$\boldsymbol{R}$ 采用自适应更新后，结果继续改善，表明训练过程中噪声水平并非固定不变，自适应更新更有利于捕捉训练中波动程度的阶段性变化。

因此，在第二阶段中引入自适应噪声更新能够有效提升长周期预测稳定性。

4.5 功率预算代理实验结果

表 10 功率预算代理实验结果

Table 10 Results of the power-budget proxy experiment

方法	峰值功率误差/%	预算越界率/%	误接纳率/%	误拒绝率/%
Stage-1-only	8.7	12.5	10.2	7.6
Carbontracker	5.4	7.1	6.2	5.1
Two-Stage	2.9	4.0	3.4	3.0

从表 10 功率预算代理实验结果可以看出，Stage-1-only 由于长窗口误差较大，在预算判断中更容易出现峰值估计偏差和接纳误判，从而导致较高的预算越界率。CarbonTracker 在这方面已有明显改善，但在峰值估计和误接纳率上仍有一定偏差。Two-Stage 的 4 项指标均为最优，尤其在预算越界率和误接纳率方面下降更为明显，说明更准确的任务级能耗预测能够转化为更稳定的预算判断效果。这表明，任务级能耗预测的改进不仅体现在误差指

标上，也会直接影响后续资源预算和任务接纳决策的可靠性。

5 总结

本文围绕异构数据中心深度学习训练任务能耗预测问题，提出一种结合操作级非线性建模与在线动态校准的两阶段预测方法。通过构建融合任务结构特征与硬件族特性的事先能耗模型，实现了跨任务、跨硬件环境下的稳定初始预测；进一步引入局部回归与残差状态空间建模，实现了基于少量训练轮次观测数据的在线自适应校准，有效抑制长周期预测误差累积。实验结果表明，所提方法在不同模型规模与 GPU 架构场景下均显著优于现有对比方法，具备良好的泛化能力与工程稳定性。

本文方法可作为数据中心能量管理系统中的核心能耗感知与预测模块，与电网调度自动化系统形成协同闭环。其事先预测结果可在日前调度阶段转化为数据中心可调负荷功率曲线，作为系统负荷预测与备用容量配置的重要输入，用于提升新型柔性负荷接入条件下的调度安全裕度；在线校准阶段输出的滚动能耗预测可嵌入实时调度与自动发电控制环节，对数据中心功率响应能力进行动态修正，降低预测不确定性对频率稳定与线路潮流的影响。同时，在需求响应与电力市场场景中[35]，预测结果可支撑数据中心参与日前申报与实时竞价决策，推动以训练任务为粒度的算力负荷资源化与聚合调控。在安全约束调度方面，已有物理信息引导的智能调度方法[36]；本文的滚动功率预测可作为后续与此类方法衔接的候选输入。

本文仍存在一定局限性，一方面，本文主要关注深度学习任务级能耗预测，并通过功率预算代理实验初步验证预测结果对任务接纳和预算判断的影响，但尚未建立完整的能耗-通信-时延联合调度模型。另一方面，本文实验选取 3 类代表性 GPU 训练任务验证方法有效性，尚未覆盖推荐、语音、生成式模型训练、推理服务等更多数据中心负载。后续将进一步扩展任务类型和运行数据规模，并结合链路带宽、迁移数据量和分布式训练通信开销，开展面向算力-电力-通信协同的联合调度研究。

综上，本文提出的两阶段能耗预测方法不仅提升了数据中心训练负载能耗感知精度，也为算力负荷在新型电力系统中的规模化协同调度与市场化参与提供了关键技术支撑。

参考文献

[1] 蒲天骄,赵琦,王新迎.电力人工智能技术研究框架、应用现状及展望[J].电网技术,2025,49(05):1751-1770.
T. Pu, Q. Zhao, and X. Wang, Research framework, application status and prospect of artificial intelligence technology in power systems, Power System Technology, vol. 49, no. 5, pp. 1751–1770, 2025 (in Chinese).

[2] Ahrabi R R, Mousavi A, Mohammadi E, et al. AI-Driven Data Center Energy Profile, Power Quality, Sustainable Sitting, and Energy Management: A Comprehensive Survey[C]//2025 IEEE Conference on Technologies for Sustainability (SusTech). IEEE, 2025: 1-8.

[3] Vesa A V, Cioara T, Anghel I, et al. Energy flexibility prediction for data center engagement in demand response programs[J]. Sustainability, 2020, 12(4): 1417.

[4] 仲悟之,黄思宇,崔杨,等.考虑源荷不确定性的风电–光热–碳捕集虚拟电厂协调优化调度[J].电网技术,2020,44(09):3424-3432.
W. Zhong, S. Huang, Y. Cui, et al., W-S-C Capture Coordination in Virtual Power Plant Considering Source-load Uncertainty, vol. 44, no. 9, pp. 3424–3432, 2020 (in Chinese).

[5] 刘方,陈祥洲,周江昕,等.考虑数据中心共享储能与计算负荷时空迁移特性的虚拟电厂优化运行方法[J/OL]. 电网技术,1-17[2026-01-30].
F. Liu, X. Chen, J. Zhou, et al., Optimal operation method of virtual power plant considering shared energy storage of data center and spatio-temporal migration characteristics of computing load, Power System Technology, pp. 1–17, 2026 (in Chinese).

[6] Deepika T, Prakash P. Power consumption prediction in cloud data center using machine learning[J]. Int. J. Electr. Comput. Eng.(IJECE), 2020, 10(2): 1524-1532.

[7] Wang Z X, Lu J R, Wang P, et al. Two-Stage Energy Prediction With Prior Estimation and Dynamic Adaptation for Symbiotic IOV[J]. IEEE Internet of Things Journal, 2025.

[8] 吴刚,高赐威,陈宋宋,等.考虑需求响应的数据中心用电负荷优化研究综述[J].电网技术,2018,42(11):3782-3788.
G. Wu, C. Gao, S. Chen, et al., Review on optimization of data center power load considering demand response, Power System Technology, vol. 42, no. 11, pp. 3782–3788, 2018 (in Chinese).

[9] 顾炯炯,李佩珊,曹伟朋,等.面向算力互联网的柔性计算调度机制研究[J].通信学报,2025,46(10):326-338.
J. Gu, P. Li, W. Cao, et al., Research on flexible computing scheduling mechanism for computing power internet, Journal on Communications, vol. 46, no. 10, pp. 326–338, 2025 (in Chinese).

[10] 胡亚辉,张宸康,王越嶙,等.基于算网状态感知的多集群 GPU 算力资源调度平台设计与实现[J].通信学报,2025,46(10):175-190.
Y. Hu, C. Zhang, Y. Wang, et al., Design and implementation of multi-cluster GPU computing resource scheduling platform based on network and computing state awareness,Journal on Communications, vol. 46, no. 10, pp. 175–190, 2025 (in Chinese).

[11] Tang X, Liao X, Zheng J, et al. Energy efficient job scheduling with workload prediction on cloud data center[J]. Cluster Computing, 2018, 21(3): 1581-1593.

[12] Ahmed K M U, Bollen M H J, Alvarez M. A review of data centers energy consumption and reliability modeling[J]. IEEE access, 2021, 9: 152536-152563.

[13] Ma H, Ding A. Method for evaluation on energy consumption of cloud computing data center based on deep reinforcement learning[J]. Electric Power Systems Research, 2022, 208: 107899.

[14] Hsu Y F, Matsuda K, Matsuoka M. Self-aware workload forecasting in data center power prediction[C]//2018 18th IEEE/ACM International Symposium on Cluster, Cloud and Grid Computing (CCGRID). IEEE, 2018: 321-330.

[15] Anthony L F W, Kanding B, Selvan R. Carbontracker: Tracking and predicting the carbon footprint of training deep learning models[J]. arXiv preprint arXiv:2007.03051, 2020.

[16] You J, Chung J W, Chowdhury M. Zeus: Understanding and optimizing {GPU} energy consumption of {DNN} training[C]//20th USENIX Symposium on Networked Systems Design and Implementation (NSDI 23). 2023: 119-139.

[17] Sharma C, Tiwari P K, Agarwal G. Energy-Efficient Resource Allocation Approaches for Cloud Computing Systems: A Survey and Taxonomy[J]. Smart Systems: Innovations in Computing: Proceedings of SSIC 2021, 2021: 479-484.

[18] Lewis A W, Ghosh S, Tzeng N F. Run-time Energy Consumption Estimation Based on Workload in Server Systems[J]. HotPower, 2008, 8: 17-21.

[19] Katal A, Dahiya S, Choudhury T. Energy efficiency in cloud computing data centers: a survey on software technologies[J]. Cluster Computing, 2023, 26(3): 1845-1875.

[20] Zhou Y, Li N, Li H, et al. Regression cloud models and their applications in energy consumption of data center[J]. Journal of Electrical and Computer Engineering, 2015, 2015(1): 143071.

[21] Jin C, Bai X, Zhang X, et al. A measurement-based power consumption model of a server by considering inlet air temperature[J]. Energy, 2022, 261: 125126.

[22] von Kistowski J, Grohmann J, Schmitt N, et al. Predicting server power consumption from standard rating results[C]//Proceedings of the 2019 ACM/SPEC International Conference on Performance Engineering. 2019: 301-312.

[23] Saillant T, Weill J C, Mougeot M. Predicting job power consumption based on rjms submission data in hpc systems[C]//International Conference on High Performance Computing. Cham: Springer International Publishing, 2020: 63-82.

[24] Antici F, Borghesi A, Kiziltan Z, et al. An Online Algorithm for Power Consumption Prediction of HPC Workload[J]. Future Generation Computer Systems, 2025: 108064.

[25] Fischer R. Ground-Truthing AI Energy Consumption: Validating CodeCarbon Against External Measurements[J]. arXiv preprint arXiv:2509.22092, 2025.

[26] Mocanu E, Nguyen P H, Gibescu M, et al. Deep learning for estimating building energy consumption[J]. Sustainable Energy, Grids and Networks, 2016, 6: 91-99.

[27] Lannelongue L, Grealey J, Inouye M. Green algorithms: quantifying the carbon footprint of computation[J]. Advanced science, 2021, 8(12): 2100707.

[28] 马博,余应洁,吴莎尘,等.云边端异构算力网络计算任务分割与路径优化方法研究[J].电子学报,2025,53(06):1847-1864.
B. Ma, Y. Yu, S. Wu, et al., Task Segmentation and Path Optimization in Heterogeneous Cloud-Edge-End Computing Power Network, Acta Electronica Sinica, vol. 53, no. 6, pp. 1847–1864, 2025.

[29] 李丹阳,吴良基,刘慧,等.基于深度强化学习的数据中心热感知能耗优化方法[J].计算机科学,2024,51(S1):738-745.
D. Li, L. Wu, H. Liu, et al., Thermal-aware energy consumption optimization method for data centers based on deep reinforcement learning,Computer Science, vol. 51, no. S1, pp. 738–745, 2024 (in Chinese).

[30]李鸿杨,赵宇,宋凡,等.电力调度自动化系统的数据融合与处理技术分析[J].电子技术,2025,54(10):348-349.
H. Li, Y. Zhao, F. Song, et al., Analysis of data fusion and processing technology for power dispatch automation system, Electronic Technology, vol. 54, no. 10, pp. 348–349, 2025 (in Chinese).

[31]鲁宗相,黄瀚,单葆国,等.高比例可再生能源电力系统结构形态演化及电力预测展望[J].电力系统自动化,2017,41(09):12-18.
Z. Lu, H. Huang, B. Shan, et al., Morphological evolution model and power forecasting prospect of future electric power systems with high proportion of renewable energy, Automation of Electric Power Systems, vol. 41, no. 9, pp. 12–18, 2017 (in Chinese).

[32]Strubell E, Ganesh A, McCallum A. Energy and policy considerations for deep learning in NLP[C]//Proceedings of the 57th annual meeting of the association for computational linguistics. 2019: 3645-3650.

[33]林一凡， 付兵彬， 鲁宗相， 等． 双碳目标下甘肃构建新型电力系统的安全风险管控实践与应对策略研究． 新型电力系统． 2025， 3(1)： 1-11．
LIN Yifan， FU Bingbin， LU Zongxiang ，et al． Research and Experience on the Security Risks Control Countermeasures of Constructing New Type Power System in Gansu Province Under the Dual Carbon Goals． New Type Power Systems． 2025， 3(1)： 1-11(in Chinese)．

[34]吴翔宇， 荀超， 翁宇游 ，等． 基于分层证据推理的新型电力系统评价方法． 新型电力系统． 2025， 3(4)： 445-465．
WU Xiangyu ， XUN Chao ， WENG Yuyou ， et al， ZHUANG Pengwei ， XU Xun ， ZHENG Wendi ， SHAO Zhenguo ， JIANG Changxu． Evaluation Method Based on Hierarchical Evidence Reasoning of New-type Power System． New Type Power Systems． 2025， 3(4)： 445-465(in Chinese)

[35]王博钰，许小峰，曹正，等．基于多维度风险度量的代理购电多市场交易策略研究[J]．电网技术，2025，49(3)：1032-1044．
WANG Boyu，XU Xiaofeng，CAO Zheng，et al．Research on multi-market trading strategies for agency power purchase based on multi-dimensional risk measurement[J]．Power System Technology，2025，49(3)：1032-1044(in Chinese)．

[36]张龙飞，徐辉，朱克东，等．考虑安全约束的物理信息引导智能调度方法研究[J]．电网技术，2026，50(3)：1061-1070．
ZHANG Longfei，XU Hui，ZHU Kedong，et al．Research on security-constrained physics-informed intelligent dispatch method[J]．Power System Technology，2026，50(3)：1061-1070(in Chinese)．



收稿日期：2026-08-20。

作者简介：

范俊秋(1991)，男，通信作者，博士，研究方向为电算协同及极端电力安全风险研究，E-mail：fans_edu_gzdx@yeah.net；

刘明顺(1986)，男，硕士，研究方向为电网运行与控制，E-mail：lms2800@qq.com；

王明阳(1995)，男，硕士，研究方向为电网运行与控制，E-mail：13263328365@163.com；

马覃峰(1982)，男，硕士，主要研究方向为电网运行与控制，E-mail：66105768@qq.com；

吴启迪(2002)，男，学士，研究方向为配网调度自动化，E-mail：1835644049@qq.com；

安甦(1988)，男，博士，高级工程师，研究方向为大电网优化运行与安全稳定分析，E-mail：769853242@qq.com；

黎灿兵(1979)，男，教授，博士生导师，研究方向为电力系统分析与控制，E-mail：licanbing@sjtu.edu.cn。

（责任编辑　马晓华　明月）